

UNIVERSIDAD NACIONAL DE INGENIERÍA
FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS



SISTEMA DE INTELIGENCIA DE NEGOCIOS
Examen Sustitutorio
INFORME TECNICO

DOCENTE:

Dr. Ing. Hilario Aradiel Castañeda

ESTUDIANTE:

Larico Cruz, Diego Cesar

Lima, Perú

2025-2

Índice General

1.	RESUMEN EJECUTIVO	4
2.	CONTEXTO DEL NEGOCIO Y PLANTEAMIENTO DEL PROBLEMA	5
3.	OBJETIVOS DE LA SOLUCIÓN DE INTELIGENCIA DE NEGOCIOS	5
3.1.	Objetivo General:	5
3.2.	Objetivos Específicos:	5
4.	ANÁLISIS DEL DATASET	6
4.1.	Descripción de la fuente de datos	6
4.2.	Estructura y campos relevantes	6
4.3.	Volumen y periodo de la información	7
4.4.	Calidad de datos y hallazgos	7
5.	ARQUITECTURA DE LA SOLUCIÓN BI (GCP)	8
5.1.	Diagrama de arquitectura	8
5.2.	Flujo end-to-end de datos	8
5.2.1.	Ingesta:	8
5.2.2.	Procesamiento y Limpieza:	8
5.2.3.	Transformación y Modelado:	8
5.2.4.	Visualización y Consumo:	9
5.3.	Herramientas y tecnologías utilizadas (servicios)	9
6.	PROCESO ETL / ELT	9
6.1.	Estrategia de ingesta	9
6.2.	Transformaciones aplicadas	10
6.3.	Reglas de calidad de datos	10
6.4.	Evidencia de ejecución	10
7.	MODELO DIMENSIONAL	13
7.1.	Diseño del modelo analítico	13
7.2.	Tabla de hechos	13
7.3.	Tablas de dimensiones	14
7.3.1.	dim_tiempo:	14
7.3.2.	dim_ubicacion:	14
7.3.3.	dim_especialidad:	14
7.4.	Definición del grano	14
8.	DEFINICIÓN DE KPIS	14
8.1.	KPIs académicos	14
8.2.	KPIs de gestión	15
8.3.	Fórmulas y fuentes de datos	15

9.	DASHBOARDS Y VISUALIZACIÓN	16
9.1.	Dashboards desarrollados	16
9.2.	KPIs visualizados	17
9.3.	Filtros y capacidades de análisis	17
9.4.	Evidencia de despliegue	17
10.	REPRODUCIBILIDAD DE LA SOLUCIÓN	19
11.	RESULTADOS Y ANÁLISIS	22
12.	CONCLUSIONES	22
13.	LIMITACIONES Y MEJORAS FUTURAS	22
14.	REFERENCIAS Y ANEXOS	23

1. RESUMEN EJECUTIVO

El presente proyecto implementa una solución integral de Inteligencia de Negocios para el CEPREUNI, migrando la gestión de datos de admisión desde procesos manuales en archivos planos hacia una arquitectura moderna ELT Serverless en Google Cloud Platform. Mediante la orquestación de servicios gestionados, se estableció un flujo automatizado que ingesta datos crudos en Cloud Storage, los procesa y limpia masivamente con Dataproc (PySpark) y los consolida en un Data Warehouse en BigQuery bajo un diseño de Modelo de Estrella. Esta infraestructura asegura la integridad, escalabilidad y disponibilidad inmediata de la información histórica de los ciclos 2024 y 2025, eliminando los silos de información y reduciendo a cero la carga operativa manual.

Como resultado, se habilitó una capa de visualización analítica en Looker Studio que democratiza el acceso a la información estratégica. A través de tableros de mando interactivos, la dirección académica y administrativa ahora cuenta con la capacidad de monitorear en tiempo real indicadores clave (KPIs) sobre la demanda geográfica, la efectividad de las convocatorias y el rendimiento académico por especialidad, transformando el proceso de toma de decisiones de uno reactivo a uno proactivo y basado en evidencia empírica.

2. CONTEXTO DEL NEGOCIO Y PLANTEAMIENTO DEL PROBLEMA

Contexto del Negocio: El Centro de Estudios Preuniversitarios de la Universidad Nacional de Ingeniería (CEPREUNI) es una institución académica de alta exigencia encargada de la preparación y selección de estudiantes para el ingreso a la universidad. Cada año, gestiona múltiples ciclos académicos (Ordinario, Intensivo, etc.) recibiendo miles de postulantes de todo el país que compiten por vacantes en diversas especialidades de ingeniería y arquitectura. La institución genera grandes volúmenes de datos transaccionales referentes a inscripciones, notas, asistencia y resultados de admisión.

Planteamiento del Problema: Actualmente, la gestión de esta información presenta desafíos significativos:

- **Silos de Información:** Los datos históricos de los postulantes (2024-2025) se encuentran dispersos en archivos planos (CSV/Excel) y sistemas legados, dificultando una visión integral de la evolución académica.
- **Procesos Manuales:** La generación de reportes de ingresantes y estadísticas demográficas se realiza mediante procesos manuales propensos a errores humanos, lo que retrasa la toma de decisiones estratégicas.
- **Falta de Inteligencia de Negocios:** No existe una plataforma centralizada que permita responder preguntas clave en tiempo real,

3. OBJETIVOS DE LA SOLUCIÓN DE INTELIGENCIA DE NEGOCIOS

3.1. Objetivo General:

Implementar una solución de Inteligencia de Negocios (BI) en Google Cloud Platform, que permita centralizar, procesar y visualizar los datos de admisión del CEPREUNI para facilitar la toma de decisiones basada en datos.

3.2. Objetivos Específicos:

- a) **Modernización Tecnológica:** Migrar el almacenamiento de datos históricos desde archivos locales a una arquitectura en Google Cloud Storage y BigQuery.
- b) **Automatización del Procesamiento:** Implementar flujos de limpieza y transformación de datos (Data Quality) utilizando Dataproc (PySpark) y SQL, eliminando la necesidad de manipulación manual de archivos.
- c) **Análisis de Rendimiento (Académico):** Implementar indicadores como el puntaje promedio, tasas de efectividad (Ingresantes/Postulantes), visualizados en Looker Studio.

4. ANALISIS DEL DATASET

4.1. Descripción de la fuente de datos

La fuente de información principal corresponde a los Datos Abiertos de Admisión del CEPREUNI. Se trata de un conjunto de datos estructurado en formato CSV que consolida la información de los postulantes inscritos en los procesos de admisión recientes. Este dataset actúa como la fuente para el análisis del perfil del postulante y los resultados de su proceso de admisión.

4.2. Estructura y campos relevantes

Se realizó un análisis exploratorio de datos (EDA) para conocer la estructura y características del dataset, además de apoyarnos del diccionario de datos proporcionado por Datos Abiertos.

Columnas	Descripción	RELEVANCIA
IDHASH	Identificador anónimo único para cada alumno, si el alumno participa en más de una postulación debería aparecer nuevamente con el mismo identificador.	RELEVANTE
COLEGIO	Nombre del colegio de procedencia del alumno del centro preuniversitario	NO RELEVANTE
COLEGIO_DEPA	Departamento donde se encuentra ubicado el colegio del alumno del centro preuniversitario	NO RELEVANTE
COLEGIO_PROV	Provincia donde se encuentra ubicado el colegio del alumno del centro preuniversitario	NO RELEVANTE
COLEGIO_DIST	Distrito donde se encuentra ubicado el colegio del alumno del centro preuniversitario	NO RELEVANTE
COLEGIO_PAIS	País de procedencia del alumno del centro preuniversitario	NO RELEVANTE
COLEGIO_ANIO_EGRESO	Año en que egresó del colegio	NO RELEVANTE
ESPECIALIDAD	nombre de la especialidad profesional a la que postula	RELEVANTE
ANIO_POSTULA	Año en que postula	RELEVANTE
CICLO_POSTULA	Ciclo del año que postula	RELEVANTE
DOMICILIO_DEPA	Departamento donde se encuentra ubicado el domicilio del alumno del centro preuniversitario	RELEVANTE
DOMICILIO_PROV	Provincia donde se encuentra ubicado el domicilio del alumno del centro preuniversitario	RELEVANTE
DOMICILIO_DIST	Distrito donde se encuentra ubicado el domicilio del alumno del centro preuniversitario	RELEVANTE
ANIO_NACIMIENTO	Año de nacimiento del alumno del centro preuniversitario	RELEVANTE

NACIMIENTO_PAIS	Nombre del pais de nacimiento del alumno del centro preuniversitario	NO RELEVANTE
NACIMIENTO_DEPA	Departamento donde se encuentra ubicado el lugar de nacimiento del alumno del centro preuniversitario	NO RELEVANTE
NACIMIENTO_PROV	Provincia donde se encuentra ubicado el lugar de nacimiento del alumno del centro preuniversitario	NO RELEVANTE
NACIMIENTO_DIST	Distrito donde se encuentra ubicado el lugar de nacimiento del alumno del centro preuniversitario	NO RELEVANTE
SEXO	Sexo del alumno del centro preuniversitario: MASCULINO, FEMENINO	NO RELEVANTE
CALIF_FINAL	Puntaje o calificación final obtenido en su período de estudios pre universitarios	RELEVANTE
INGRESO	Si el postulante fue admitido (ingresó a la UNI): SI, NO	RELEVANTE
MODO_INGRESO	Modalidad de ingreso: ORDINARIO, DIRECTO	RELEVANTE

Fuente: Elaboración propia

Justificación:

Se catalogó como no relevante la información relacionada a colegios, CEPREUNI no realiza convenios con colegios específicos por lo que esta información no es necesaria para nuestro análisis, la información relacionada al nacimiento tampoco es relevante, solo consideramos relevante la información de domicilio actual; por otro lado, la información relacionada a sexo la consideré no relevante debido a que CEPREUNI no realiza procesos de admisión segmentados.

Link EDA:

<https://colab.research.google.com/drive/11UtOw6qcXk4lGLeAWZkwcSxBqfA5C-Q3?usp=sharing>

4.3. Volumen y periodo de la información

El dataset contiene 8470 registros de estudiantes durante algún periodo académico específico, además de contar con 23 variables.

Periodo de información: El dataset abarca los periodos de admisión 2024-1, 2024-2 y 2025-1.

4.4. Calidad de datos y hallazgos

El dataset no presentó valores NULL, sin embargo vemos que existen valores no homogenizados en la escritura de los departamentos.

Hallazgos significativos:


- Hay un total de 5808 alumnos registrados, se entiende que muchos de ellos postularon en 2 o 3 ocasiones.
- Todos los postulantes provienen de algún colegio de Perú

- Solo se especifica la “especialidad” a los estudiantes que lograron ingresar, no se conoce las intenciones de los estudiantes que no lograron entrar a la universidad.

5. ARQUITECTURA DE LA SOLUCIÓN BI (GCP)

5.1. Diagrama de arquitectura

Para el desarrollo de la solución se optó por una arquitectura en Google Cloud Platform.



5.2. Flujo end-to-end de datos

El flujo de datos se divide en cuatro etapas:

5.2.1. Ingesta:

- Los datos históricos de admisión, originalmente en formato CSV, son extraídos y cargados al Google Cloud Storage (GCS) en un bucket dedicado. Esta etapa constituye la "Zona Bronce" o Raw, donde la información reside en su formato nativo e inmutable.

5.2.2. Procesamiento y Limpieza:

- Se utiliza Google Dataproc para ejecutar trabajos de limpieza automatizados (PySpark).
- El script lee los archivos crudos del bucket, estandariza cabeceras, elimina espacios en blanco y aplica transformaciones de tipos de datos.
- El resultado se carga en una tabla dentro de BigQuery, actuando como puente entre el archivo físico y la base de datos analítica.

5.2.3. Transformación y Modelado:

- Ya dentro de BigQuery, se ejecutan scripts SQL para transformar la tabla plana en un Modelo Dimensional (Esquema de Estrella).

- Se generan tablas de Dimensiones (dim_tiempo, dim_especialidad, dim_ubicacion) normalizando los atributos categóricos.
- Se construye la Tabla de Hechos (fact_postulaciones), donde se calculan métricas clave (puntajes, edad) constituyendo la "Zona Oro" o Curated lista para el consumo.

5.2.4. Visualización y Consumo:

- Finalmente, Looker Studio se conecta de forma nativa a las tablas modeladas en BigQuery.
- Se realiza una combinación de datos entre la tabla de hechos y las dimensiones para permitir el filtrado dinámico.

5.3. Herramientas y tecnologías utilizadas (servicios)

Para la implementación de la arquitectura de datos en la nube, se seleccionaron los siguientes servicios gestionados de Google Cloud Platform (GCP), garantizando escalabilidad, rendimiento y eficiencia operativa:

- Google Cloud Storage (GCS): Actúa como el Data Lake de la solución. Es un servicio de almacenamiento de objetos altamente escalable y duradero donde se centralizan los archivos crudos (.csv) provenientes de los sistemas de origen. Su función principal es servir como la "Zona de Aterrizaje" o capa Bronce, resguardando la data histórica en su formato original antes de cualquier procesamiento.
- Google Cloud Dataproc: Es el servicio gestionado de Apache Spark y Hadoop utilizado para la capa de procesamiento (Compute). En esta solución, se utiliza en su modalidad Serverless para ejecutar scripts de PySpark encargados de la limpieza, estandarización y curación de los datos. Dataproc permite transformar grandes volúmenes de información en memoria de manera distribuida, entregando datos limpios a la siguiente capa sin necesidad de administrar infraestructura de servidores.
- Google BigQuery: Es el Data Warehouse empresarial serverless de la solución. BigQuery almacena tanto los datos procesados (Capa Plata) como el Modelo Dimensional final (Capa Oro). Su potente motor SQL permite realizar transformaciones complejas y ejecutar consultas analíticas a gran velocidad, sirviendo como la fuente de verdad única para los tableros de control en Looker Studio.

6. PROCESO ETL / ELT

6.1. Estrategia de ingesta

La carga de archivos csv y su colocación se realiza mediante comandos CLI.

```
gsutil cp $CSV_FILE gs://$BUCKET_NAME/raw/$CSV_FILE
```

Comando para inserción del csv a un bucket previamente definido.

6.2. Transformaciones aplicadas

- Tratamiento de Cadenas: Aplicación de funciones UPPER() y TRIM() a todos los campos de texto (Colegios, Distritos, Especialidades) para eliminar espacios en blanco redundantes y unificar mayúsculas/minúsculas, resolviendo inconsistencias como "Lima" vs "LIMA".
- Renombrado de Columnas: Estandarización de nombres de cabeceras para cumplir con los estándares de nomenclatura de BigQuery.
- Cálculo de Edad: Generación del campo edad mediante la diferencia aritmética entre el ANIO_POSTULA y ANIO_NACIMIENTO

6.3. Reglas de calidad de datos

Para garantizar la fiabilidad de la información presentada en los tableros de mando, se implementaron las siguientes reglas de calidad durante el procesamiento del pipeline:

Regla de Completitud:

- *Problema:* Existencia de valores nulos en el campo de calificación final (CALIF_FINAL) para alumnos ausentes.
- *Acción:* Imputación automática de valores nulos a 0.0 utilizando la función COALESCE, asegurando que los promedios académicos no se vean distorsionados por la ausencia de datos.

Regla de Unicidad (Uniqueness):

- *Problema:* Riesgo de duplicidad al generar las tablas de dimensiones.
- *Acción:* Aplicación de cláusulas DISTINCT en la creación de las dimensiones maestras (dim_especialidad, dim_ubicacion y dim_tiempo). Además, se utilizó el IDHASH como identificador único para verificar que no existan registros duplicados en la tabla de hechos.

6.4. Evidencia de ejecución

Definición de variables y habilitación de servicios

```
dlaricocruz@cloudshell:~ (si807-g9)$ export PROJECT_ID="si807-g9"
export REGION="us-central1"
export BUCKET_NAME="EX_SUSTI_BUCKET"
export DATASET_NAME="cepreuni_bi"
export TABLE_NAME="cepre_uni"
export CSV_FILE="Datos abiertos cepre 2024_1_2025_1.csv"
dlaricocruz@cloudshell:~ (si807-g9)$ gcloud config set project $PROJECT_ID
gcloud services enable \
  storage-component.googleapis.com \
  dataproc.googleapis.com \
  bigquery.googleapis.com
Updated property [core/project].
Operation "operations/acat.p2-604554919714-8dad131c-6d2d-415f-b782-3f3f85149ee3" finished successfully.
```

Creación de carpetas en cloud storage

```
dlaricocruz@cloudshell:~ (si807-g9)$
gsutil mb -l $REGION gs://$BUCKET_NAME/

touch .keep
gsutil cp .keep gs://$BUCKET_NAME/raw/.keep
gsutil cp .keep gs://$BUCKET_NAME/scripts/.keep
rm .keep

Creating gs://ex-susti-bucket/...
Copying file:///keep [Content-Type=application/octet-stream]...
/ [1 files][ 0.0 B/ 0.0 B]
Operation completed over 1 objects.
Copying file:///keep [Content-Type=application/octet-stream]...
/ [1 files][ 0.0 B/ 0.0 B]
Operation completed over 1 objects.
```

Carga del csv en la carpeta de raw

```
dlaricocruz@cloudshell:~ (si807-g9)$ gsutil cp $CSV_FILE gs://$BUCKET_NAME/raw/$CSV_FILE
Copying file:///Datos abiertos_cepre_2024_1_2025_1.csv [Content-Type=text/csv]...
\ [1 files][ 2.4 MiB/ 2.4 MiB]
Operation completed over 1 objects/2.4 MiB.
```

Mediante CLI podemos crear el código para la limpieza del csv, luego lo cargamos en la carpeta scripts

```
dlaricacruz@cloudshell:~ (si807-g9)$ cat <<EOF > etl_cepre_spark.py
import sys
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, upper, trim, when

# CONFIGURACIÓN
BUCKET_NAME = "$BUCKET_NAME"
DATASET_NAME = "$DATASET_NAME"
TABLE_NAME = "$TABLE_NAME"
CSV_PATH = f"gs://{BUCKET_NAME}/raw/$CSV_FILE"


spark = SparkSession.builder \
    .appName("ETL-CepreUni") \
    .getOrCreate()

# LEER
df_raw = spark.read \
    .option("header", True) \
    .option("inferSchema", True) \
    .save()overwrite") \\\Bucket", BUCKET_NAME) \\\})" \\\GRESO")))) \\\}) \\\
dlaricacruz@cloudshell:~ (si807-g9)$ gsutil cp etl_cepre_spark.py gs://$BUCKET_NAME/scripts/etl_cepre_spark.py
Copying file://etl_cepre_spark.py [Content-Type=text/x-python]...
/ [1 files][ 1.3 KiB/ 1.3 KiB]
Operation completed over 1 objects/1.3 KiB.
```

Ejecución del job de limpieza y creación de dataset

[illegible]

Verificamos en bigquery



Ahora generamos nuestras tablas de dimensiones y hechos

```
dlaricocruz@cloudshell:~ (si807-g9)$ bq query --use_legacy_sql=false --project_id=$PROJECT_ID \
"CREATE OR REPLACE TABLE \`${PROJECT_ID}.${DATASET_NAME}.dim_tiempo\` AS
SELECT DISTINCT
  ABS(FARM_FINGERPRINT(CONCAT(ANIO_POSTULA, '-', CICLO_POSTULA))) as id_tiempo,
  CONCAT(ANIO_POSTULA, '-', CICLO_POSTULA) as periodo,
  CAST(ANIO_POSTULA AS INT64) as anio,
  CAST(CICLO_POSTULA AS INT64) as ciclo
FROM \`${PROJECT_ID}.${DATASET_NAME}.${TABLE_NAME}\`
WHERE ANIO_POSTULA IS NOT NULL;"


# Dimensión Ubicación
bq query --use_legacy_sql=false --project_id=$PROJECT_ID \
"CREATE OR REPLACE TABLE \`${PROJECT_ID}.${DATASET_NAME}.dim_ubicacion\` AS
SELECT DISTINCT
  ABS(FARM_FINGERPRINT(CONCAT(DOMICILIO_DEPA, DOMICILIO_PROV, DOMICILIO_DIST))) as id_ubicacion,
  DOMICILIO_DEPA as departamento,
  DOMICILIO_PROV as provincia,
  DOMICILIO_DIST as distrito,
  CASE
    WHEN DOMICILIO_DEPA IN ('LIMA', 'CALLAO') THEN 'LIMA METROPOLITANA'
    ELSE 'PROVINCIA'
  END as macro_zona
FROM \`${PROJECT_ID}.${DATASET_NAME}.${TABLE_NAME}\`
WHERE ANIO_POSTULA IS NOT NULL, \`${TABLE_NAME}\` filas fácilmente,)) as edad,IST))) as id_ubicacion,

Waiting on bqjob_r2545a27c45428d8a_0000019b421a49bc_1 ... (1s) Current status: DONE
Created si807-g9.cepreuni_bi.dim_tiempo

Waiting on bqjob_r644f49a9ce6ba91f_0000019b421c54f1_1 ... (1s) Current status: DONE
Created si807-g9.cepreuni_bi.dim_ubicacion

Waiting on bqjob_r5735a45ff49e69be_0000019b421dc291_1 ... (1s) Current status: DONE
Created si807-g9.cepreuni_bi.dim_especialidad
```

Verificamos




Entramos a LookerStudio y mediante conexión nativa con Bigquery seleccionamos el dataset.

PROYECTOS RECIENTES	Project	Conjunto de datos	Table
MIS PROYECTOS PROYECTOS COMPARTIDOS CONSULTA PERSONALIZADA CONJUNTOS DE DATOS PÚBLICOS	Search Projects Enter Project id manually	Search Datasets segment_31	Search Tables exam_uni dim_especialidad dim_tiempo [5] dim_ubicacion fact_postulaciones
	5887-09 PC4-8807-09 ExamFinal Practica2 Practica ETL-Retail-Analytics copart1_kampop		

7. MODELO DIMENSIONAL

7.1. Diseño del modelo analítico



Fuente: Elaboración propia

7.2. Tabla de hechos

Estructura:

- Claves Foráneas (FK): id_tiempo, id_ubicacion, id_especialidad. Estas columnas conectan la transacción con su contexto.
- puntaje_final (FLOAT64): La nota obtenida en el examen.
- edad (INT64): Edad calculada al momento de postular.
- cantidad_postulacion (INT64): Valor constante (1) para facilitar conteos simples.

- es_ingresante (INT64): Bandera binaria (1/0) que indica éxito en la admisión, fundamental para calcular tasas de efectividad.
- modalidad: Atributo de baja cardinalidad que se mantiene en la tabla de hechos para evitar dimensiones excesivamente pequeñas.
- id_postulante_hash: Identificador único del alumno para recuentos distintivos.

7.3. Tablas de dimensiones

7.3.1. dim_tiempo:

Permite el análisis temporal de la demanda.

- Atributos: id_tiempo (PK), periodo (ej. "2024-1"), año, ciclo.
- Uso: Fundamental para visualizar tendencias y comparar el rendimiento entre diferentes procesos de admisión.

7.3.2. dim_ubicacion:

Consolida la información geográfica de residencia de los postulantes.

- Atributos: id_ubicacion (PK), departamento, provincia, distrito, macro_zona.
- Uso: Permite filtrar mapas de calor y analizar la penetración del CEPREUNI en provincias vs. Lima Metropolitana.

7.3.3. dim_especialidad:

Catálogo de las carreras profesionales ofertadas.

- Atributos: id_especialidad (PK), carrera.
- Uso: Permite rankings de demanda y selectividad por carrera (ej. Ing. Civil vs. Arquitectura).

7.4. Definición del grano

El grano (granularity) del modelo se define como "una fila por cada postulación única de un estudiante a una especialidad en un ciclo académico específico"

8. DEFINICIÓN DE KPIS

8.1. KPIs académicos

Indicador (KPI)	Descripción Funcional	Objetivo del Negocio
Puntaje Promedio (General)	Calificación media obtenida por el total de la masa de postulantes en el examen final.	Evaluar el nivel base de preparación con el que llegan los estudiantes al CEPREUNI.
Puntaje Promedio (Ingresantes)	Calificación media obtenida exclusivamente por los alumnos que lograron una vacante.	Establecer la "vara de calidad" o línea base de exigencia académica de la institución.
Tasa de Selectividad (%)	Porcentaje de alumnos que logran ingresar respecto al total que postula.	Medir la competitividad y dificultad de ingreso por cada especialidad o ciclo.

Nota Máxima (Cómputo)	El puntaje más alto registrado en el periodo académico.	Identificar talentos sobresalientes y establecer el techo de rendimiento del ciclo.
Edad Promedio de Ingreso	Promedio de edad de los alumnos que consiguen una vacante.	Entender el perfil generacional y la madurez académica del ingresante promedio.

8.2. KPIs de gestión


Indicador (KPI)	Descripción Funcional	Objetivo del Negocio
Volumen de Postulantes	Cantidad total de inscripciones registradas en un ciclo académico.	Medir la demanda del servicio y el éxito de las campañas de convocatoria/marketing.
Total de Ingresantes	Cantidad absoluta de vacantes cubiertas en el proceso.	Monitorear el cumplimiento de metas de admisión y capacidad de aforo.
Demanda por departamentos	Distribución porcentual de postulantes según su origen (Lima y el resto de departamentos).	Evaluar el alcance geográfico y la penetración de la marca CEPREUNI a nivel nacional.
Top Carreras Demandadas	Ranking de especialidades con mayor cantidad de inscritos.	Identificar tendencias de mercado para ajustar la oferta académica o recursos por facultad.

8.3. Fórmulas y fuentes de datos

KPI / Métrica	Fórmula de Cálculo (Lógica SQL/DAX)	Fuente de Datos (Tabla.Campo)
Volumen de Postulantes	COUNT(cant_postulaciones)	fact_postulaciones.id_postulante_hash
Total de Ingresantes	SUM(es_ingresante)	fact_postulaciones.es_ingresante (Donde el valor es 1)
Tasa de Selectividad (%)	(SUM(es_ingresante) / COUNT(id_postulante_hash))	Campos calculados sobre fact_postulaciones
Puntaje Promedio (Global)	AVG(puntaje_final)	fact_postulaciones.puntaje_final
Puntaje Promedio (Ingresantes)	AVG(puntaje_final) filtrado donde es_ingresante = 1	fact_postulaciones.puntaje_final + Filtro
Edad promedio del Postulante	AVG(ANIO_POSTULA - ANIO_NACIMIENTO)	Calculado en ETL desde dim_tiempo y dim_postulante

9. DASHBOARDS Y VISUALIZACIÓN

9.1. Dashboards desarrollados




Dashboard Nro 1



ce
pre
UNI

periodo

modalidad



Dashboard Nro 2

9.2. KPIs visualizados

Se pueden visualizar los KPIs definidos previamente, de manera adicional se agregaron gráficos de barras para una mejor visualización de los datos de departamentos fuera de Lima y las carreras con más ingresantes.


9.3. Filtros y capacidades de análisis

Se agregaron los filtros por periodo académicos para poder observar el comportamiento de los KPIs académicos y de gestión de mejor manera y su comportamiento a través de los diversos procesos de admisión.


De manera adicional, en los KPIs académicos se agregó el filtro por modalidad, esto es de utilidad a la gerencia de CEPREUNI pues con ello puede realizar la premiación a los primeros puestos y realizar las correspondientes premiaciones.

9.4. Evidencia de despliegue

El despliegue se hizo gracias a la conexión nativa que tiene BigQuery con LookerStudio.




Luego para la realización de los filtros debemos unir nuestras tablas de hechos con las de dimensiones mediante una combinación de datos.



Gracias a ello, podemos realizar los filtros y que se apliquen para todas los indicadores que creemos.

Resultado final de dashboard.



Link del dashboard: <https://lookerstudio.google.com/reporting/16fd4e49-f2b7-411b-8d48-ea0863dd65bc>

Nota: A veces en el primer dashboard no se visualizan los datos, para ello seleccione los periodos con el filtro de la parte superior.

10. REPRODUCIBILIDAD DE LA SOLUCIÓN

La reproducibilidad de la solución se encuentra en el Readme del repositorio.

Se adjuntan las evidencias del desarrollo de todo el trabajo.

Definición de variables y habilitación de servicios

```
dlaricocruz@cloudshell:~ (si807-g9)$ export PROJECT_ID="si807-g9"
export REGION="us-central1"
export BUCKET_NAME="EX_SUSTI_BUCKET"
export DATASET_NAME="cepreuni_bi"
export TABLE_NAME="cepre_uni"
export CSV_FILE="Datos abiertos cepre 2024_1_2025_1.csv"
dlaricocruz@cloudshell:~ (si807-g9)$ gcloud config set project $PROJECT_ID
gcloud services enable \
    storage-component.googleapis.com \
    dataproc.googleapis.com \
    bigquery.googleapis.com
Updated property [core/project].
Operation "operations/acat.p2-604554919714-8dad131c-6d2d-415f-b782-3f3f85149ee3" finished successfully.
```

Creación de carpetas en cloud storage

```
dlaricocruz@cloudshell:~ (si807-g9)$
gsutil mb -l $REGION gs://$BUCKET_NAME/

touch .keep
gsutil cp .keep gs://$BUCKET_NAME/raw/.keep
gsutil cp .keep gs://$BUCKET_NAME/scripts/.keep
rm .keep
Creating gs://ex-susti-bucket/...
Copying file:///keep [Content-Type=application/octet-stream]...
/ [1 files][ 0.0 B/ 0.0 B]
Operation completed over 1 objects.
Copying file:///keep [Content-Type=application/octet-stream]...
/ [1 files][ 0.0 B/ 0.0 B]
Operation completed over 1 objects.
```

Carga del csv en la carpeta de raw

```
dlaricocruz@cloudshell:~ (si807-g9)$ gsutil cp $CSV_FILE gs://$BUCKET_NAME/raw/$CSV_FILE
Copying file:///Datos_abiertos_cepre_2024_1_2025_1.csv [Content-Type=text/csv]...
\ [1 files][ 2.4 MiB/ 2.4 MiB]
Operation completed over 1 objects/2.4 MiB.
```

Mediante CLI podemos crear el código para la limpieza del csv, luego lo cargamos en la carpeta scripts

```
dlaricocruz@cloudshell:~ (si807-g9)$ cat <<EOF > etl_cepre_spark.py
import sys
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, upper, trim, when

# CONFIGURACIÓN
BUCKET_NAME = "$BUCKET_NAME"
DATASET_NAME = "$DATASET_NAME"
TABLE_NAME = "$TABLE_NAME"
CSV_PATH = f"gs://{BUCKET_NAME}/raw/$CSV_FILE"

spark = SparkSession.builder \
    .appName("ETL-CepreUni") \
    .getOrCreate()


# LEER
df_raw = spark.read \
    .option("header", True) \
    .option("inferSchema", True) \
    .load(CSV_PATH)
df_raw.save(overwrite=True, bucket=BUCKET_NAME, format="parquet")

dlaricocruz@cloudshell:~ (si807-g9)$ gsutil cp etl_cepre_spark.py gs://$BUCKET_NAME/scripts/etl_cepre_spark.py
Copying file:///etl_cepre_spark.py [Content-Type=text/x-python]...
/ [1 files][ 1.3 KiB/ 1.3 KiB]
Operation completed over 1 objects/1.3 KiB.
```

Ejecución del job de limpieza y creación de dataset

[illegible]

Verificamos en bigquery



Ahora generamos nuestras tablas de dimensiones y hechos

```

dlaricocruz@cloudshell:~ (si807-g9)$ bq query --use_legacy_sql=false --project_id=$PROJECT_ID \
"CREATE OR REPLACE TABLE \`$PROJECT_ID.$DATASET_NAME.dim_tiempo\` AS
SELECT DISTINCT
  ABS(FARM_FINGERPRINT(CONCAT(ANIO_POSTULA, '-', CICLO_POSTULA))) as id_tiempo,
  CONCAT(ANIO_POSTULA, '-', CICLO_POSTULA) as periodo,
  CAST(ANIO_POSTULA AS INT64) as anio,
  CAST(CICLO_POSTULA AS INT64) as ciclo
FROM \`$PROJECT_ID.$DATASET_NAME.$TABLE_NAME\`
WHERE ANIO_POSTULA IS NOT NULL;"

# Dimensión Ubicación
bq query --use_legacy_sql=false --project_id=$PROJECT_ID \
"CREATE OR REPLACE TABLE \`$PROJECT_ID.$DATASET_NAME.dim_ubicacion\` AS
SELECT DISTINCT
  ABS(FARM_FINGERPRINT(CONCAT(DOMICILIO_DEPA, DOMICILIO_PROV, DOMICILIO_DIST))) as id_ubicacion,
  DOMICILIO_DEPA as departamento,
  DOMICILIO_PROV as provincia,
  DOMICILIO_DIST as distrito,
  CASE
    WHEN DOMICILIO_DEPA IN ('LIMA', 'CALLAO') THEN 'LIMA METROPOLITANA'
    ELSE 'PROVINCIA'
  END as macro zona
FROM \`$PROJECT_ID.$DATASET_NAME.$TABLE_NAME\`
WHERE ANIO_POSTULA IS NOT NULL;".$TABLE_NAME\`filas fácilmente,)) as edad,IST))) as id_ubicacion,


Waiting on bqjob_r2545a27c45428d8a_0000019b421a49bc_1 ... (1s) Current status: DONE
Created si807-g9.cepreuni_bi.dim_tiempo

Waiting on bqjob_r644f49a9ce6ba91f_0000019b421c54f1_1 ... (1s) Current status: DONE
Created si807-g9.cepreuni_bi.dim_ubicacion


Waiting on bqjob_r5735a45ff49e69be_0000019b421dc291_1 ... (1s) Current status: DONE
Created si807-g9.cepreuni_bi.dim_especialidad

```


Verificamos



Entramos a LookerStudio y mediante conexión nativa con Bigquery seleccionamos el dataset.




Luego para la realización de los filtros debemos unir nuestras tablas de hechos con las de dimensiones mediante una combinación de datos.



Gracias a ello, podemos realizar los filtros y que se apliquen para todas los indicadores que creamos.

Resultado final de dashboard.



Link del dashboard: <https://lookerstudio.google.com/reporting/16fd4e49-f2b7-411b-8d48-ea0863dd65bc>

11. RESULTADOS Y ANÁLISIS

- **Concentración Geográfica:** El mapa de calor reveló que, si bien existe una predominancia de postulantes de **Lima y Puno**, existe una demanda significativa proveniente de regiones clave como **Junín**. Esto sugiere oportunidades para focalizar campañas de marketing digital en dichas provincias o evaluar la apertura de otra sede.
- **Brecha de Ingreso:** Al comparar el "Puntaje Promedio General" vs. el "Puntaje Promedio de Ingresantes", se visualizó la alta competitividad del examen. En algunas carreras, el puntaje del ingresante supera en más de un **30%** al promedio general, evidenciando la rigurosidad del filtro académico.

12. CONCLUSIONES

- **Modernización Exitosa:** Se validó que la arquitectura ELT Serverless en Google Cloud es escalable, segura y capaz de centralizar la data histórica del CEPREUNI eficientemente.
- **Automatización Total:** El pipeline con PySpark eliminó el 100% de la carga manual de datos, garantizando información limpia, estandarizada y libre de errores humanos.
- **Toma de Decisiones Proactiva:** La implementación de Looker Studio transformó la gestión, permitiendo a las direcciones Académica y Administrativa visualizar KPIs críticos (demanda y rendimiento) en tiempo real.
- **Eficiencia del Modelo:** El diseño de Esquema de Estrella en BigQuery demostró ser óptimo, permitiendo consultas complejas en segundos y facilitando el análisis multidimensional.

13. LIMITACIONES Y MEJORAS FUTURAS

Una de las mayores limitaciones proviene del dataset mismo, al tener registro de solo 3 ciclos académicos, no se pudo realizar un análisis más profundo, además de ello, no se

puede visualizar la intención de especialidad de los estudiantes que no lograron ingresar, por lo que no se pudo realizar un análisis de postulantes por carrera, solo de ingresantes.

14. REFERENCIAS Y ANEXOS

Anexo 1 – notebook colab para EDA:

<https://colab.research.google.com/drive/11UtOw6qcXk4lGLeAWZkwcSxBqfA5C-Q3?usp=sharing>

Anexo 2 – Dashboard:

<https://lookerstudio.google.com/reporting/16fd4e49-f2b7-411b-8d48-ea0863dd65bc>