


UNIVERSIDAD NACIONAL DE INGENIERÍA
Facultad de Ingeniería Industrial y de Sistemas



SI807U Sistemas de Inteligencia de Negocios

Entregable Final

GRUPO: 2

DOCENTE: Dr. Ing Aradiel Castañeda, Hilario

INTEGRANTES:

Código UNI	Apellidos y Nombres	Correo	Tareas Realizadas
20220008 E	Andrade Saavedra, Navhi Giordano	giordanosaavedra0@gmail.com	● Implementación de políticas de seguridad IAM. ● Diseño y actualización de la arquitectura de la solución en GCP. ● Configuración de entornos y credenciales. ● Desarrollo y actualización del código para Dataproc. ● Organización y estandarización de la estructura de carpetas del proyecto. ● Colaboración en el procesamiento de capas de datos. ● Implementación del orquestador para automatizar el flujo de datos. ● Desarrollo de scripts de visualización y generación de gráficos. ● Integración y conexión final con Power BI. ● Documentación técnica, actualizaciones finales y control de versiones.
20220122 B	Caruzo Cieza, David	david1237891712@gmail.com	● Descripción del caso ● Descripción del proceso ETL ● Formato de datos ● Automatización del ETL ● Integración con Cloud Run CCloud Functions
20200298 H	Carhuas Romero Jhon Jesus	jhoncr885@gmail.com	● Corrección de costos ● Corrección de arquitectura ● Corrección de capa oro

2025 - II

ÍNDICE

1. INTRODUCCIÓN
 - 1.1. Objetivos
 - 1.1.1. Objetivo General
 - 1.1.2. Objetivos Específicos
 - 1.2. Alcance
 - 1.3. Metodología del trabajo
2. CAPÍTULO I: EMPRESA SELECCIONADA
 - 2.1. Generalidades de la empresa
 - 2.1.1. Nombre o Razón Social
 - 2.1.2. Giro de la Empresa
 - 2.1.3. Ubicación de la Empresa
 - 2.1.4. Misión, Visión
 - 2.1.4.1. Misión
 - 2.1.4.2. Visión
 - 2.1.4.3. Valores Institucionales
 - 2.1.5. Productos y clientes
 - 2.2. Análisis del Negocio
 - 2.2.1. Mapa de Procesos
 - 2.2.2. Cadena de Valor
 - 2.2.3. Organigrama
 - 2.2.4. Modelo CANVAS del Negocio
 - 2.3. Diagnóstico Empresarial
 - 2.3.1. Análisis FODA
 - 2.3.2. Problema Encontrado
 - 2.3.2.1. Descripción
 - 2.3.2.2. Implicancias
 - 2.3.2.3. Consecuencias
 - 2.4. Necesidades de Información y Decisiones Críticas
 - 2.5. KPI's iniciales
3. CAPÍTULO II: DESARROLLO
 - 3.1. Preguntas de Negocio
 - 3.2. KPI's Definidos
 - 3.3. Modelo Conceptual Inicial
 - 3.4. Inventario de fuentes OLTP
 - 3.5. Estrategia de Migración a la Nube
 - 3.5.1. Nube elegida
 - 3.5.1.1. Descripción
 - 3.5.1.2. Entorno en la nube
 - 3.5.1.3. Justificación de elección
 - 3.5.2. Comparación
 - 3.5.2.1. Características principales
 - 3.5.2.2. Costos
4. CAPÍTULO III: ARQUITECTURA CLOUD Y DISEÑO DE SOLUCIÓN
 - 4.1. Arquitectura General en GCP
 - 4.2. Descripción de Componentes
 - 4.2.1. Data Lake
 - 4.2.2. ETL
 - 4.2.3. Data Warehouse
 - 4.2.4. Dashboard
 - 4.3. Diseño de Seguridad y Roles
 - 4.3.1. Control de Acceso IAM
 - 4.3.2. Almacenamiento de credenciales
 - 4.4. Estructura de Carpetas y Versionamiento en Github
 - 4.4.1. Flujo GitFlow

- 5. CAPÍTULO IV: PROCESO ETL EN GOOGLE CLOUD PLATFORM
 - 5.1. Diagrama de Flujo del Proceso ETL
 - 5.2. Scripts de Extracción, Transformación y Carga
 - 5.2.1. Extracción
 - 5.2.2. Transformación
 - 5.2.3. Carga
 - 5.3. Automatización del ETL
 - 5.3.1. Orquestación con Cloud Composer
 - 5.4. Ejecución del Proceso ETL
 - 5.4.1. Análisis inicial de datos
 - 5.4.2. Ejecución del proceso automatizado del ETL
 - 5.4.3. Análisis final de datos
 - 5.4.4. Comparación de la situación inicial y situación final de los datos
 - 5.5. Bitácora Técnica de Ejecución
 - 5.5.1. Registro de ejecución
 - 5.5.2. Registro de errores
 - 5.5.3. Validación de Datos
 - 5.6. Diagrama Medallion Arquitectura
 - 5.6.1. Situación Inicial de los Datos
 - 5.6.2. Bronce
 - 5.6.3. Plata
 - 5.6.4. Oro
- 6. CAPÍTULO V: DATA WAREHOUSE CLOUD
 - 6.1. Modelo Dimensional
 - 6.1.1. Diseño Estrella / Copo de Nieve
 - 6.1.2. Diagrama de Hechos y Dimensiones
 - 6.2. Scripts SQL / DDL
 - 6.2.1. Script de Creación de Tablas en BigQuery
 - 6.2.2. Ejecución de Script de Creación de Tablas
 - 6.3. Consultas OLAP
 - 6.4. Validación de Integración con ETL
 - 6.4.1. Evidencia de Carga Correcta
 - 6.4.2. Consistencia de Datos
- 7. CAPÍTULO VI: DASHBOARD ANALÍTICO
 - 7.1. Conexión con BigQuery
 - 7.1.1. Descripción del proceso de conexión
 - 7.1.2. Evidencia de conexión
 - 7.1.3. Configuración de credenciales
 - 7.2. Dashboard Analítico
 - 7.2.1. Pestaña 1
 - 7.2.1.1. Reporte
 - 7.2.1.2. KPI's principales visualizados
 - 7.2.2. Pestaña 2
 - 7.2.2.1. Reporte
 - 7.2.2.2. KPI's principales visualizados
 - 7.2.3. Pestaña 3
 - 7.2.3.1. Reporte
 - 7.2.3.2. KPI's principales visualizados
 - 7.2.4. Pestaña 4
 - 7.2.4.1. Reporte
 - 7.2.4.2. KPI's principales visualizados
 - 7.2.5. Pestaña 4
 - 7.2.5.1. Reporte
 - 7.2.5.2. KPI's principales visualizados

- 8. CAPÍTULO VII: DOCUMENTACIÓN Y EVIDENCIA DE DESPLIEGUE
 - 8.1. Flujo de Trabajo en GCP
 - 8.1.1. Configuración por servicio
 - 8.1.2. Ejecución
 - 8.2. Flujo de Datos General
 - 8.3. Bitácora de Versionamiento
 - 8.4. Costos de Despliegue
 - 8.4.1. Estimación de costos en GCP
- 9. CAPÍTULO VIII: LIMITACIONES, PROPUESTAS Y CONCLUSIONES
 - 9.1. Limitaciones Encontradas
 - 9.2. Propuestas de Mejora
 - 9.3. Conclusiones
- 10. BIBLIOGRAFÍA

ÍNDICE

11. INTRODUCCIÓN

11.1. Objetivos

11.1.1. Objetivo General

Diseñar e implementar un sistema de Inteligencia de Negocios (BI) basado en un modelo de datos estandarizado y una arquitectura moderna en la nube GCP (Google Cloud Platform), que permita integrar, procesar y analizar los datos de tres enfermedades Diabetes, Hipertensión, Obesidad de EsSalud para mejorar la vigilancia epidemiológica, la toma de decisiones y la planificación operativa.

11.1.2. Objetivos Específicos

- **Evaluar y comparar las arquitecturas cloud para definir la estrategia óptima de migración**

Analizar costos, escalabilidad, rendimiento, seguridad y mantenimiento entre infraestructura local y Google Cloud, justificando la adopción de GCP mediante comparaciones con AWS y Azure con dimensiones clave, y proponiendo mecanismos de optimización de costos (autoscaling, spot VMs, cold storage, particionado en BigQuery).

11.2. Alcance

El alcance del proyecto comprende el análisis, diseño, construcción y despliegue de un sistema de Inteligencia de Negocios para EsSalud, orientado a la integración, procesamiento y análisis de información clínica proveniente de diagnósticos médicos de tres enfermedades (Diabetes, Hipertensión, obesidad). Incluye la implementación de un modelo de datos analítico basado en un esquema estrella, la creación de un pipeline ETL automatizado en Google Cloud Platform y la evaluación comparativa entre arquitecturas cloud para definir la estrategia óptima de migración institucional.

11.3. Metodología del trabajo

La metodología de desarrollo adoptada en el proyecto combina prácticas de gestión de versiones (GitFlow), principios de DevOps, integración continua (CI) y mecanismos de reproducibilidad orientados a asegurar que el sistema de Inteligencia de Negocios pueda ser mantenido, desplegado y mejorado de forma controlada y trazable.

- **Gestión de versiones con Git y GitFlow**

Para el control de versiones del proyecto se utiliza Git, con un flujo de trabajo basado en GitFlow, que permite separar claramente el desarrollo experimental de las versiones estables del sistema:

- ❖ Rama main

Contiene el estado estable del proyecto, correspondiente a versiones listas para ser desplegadas (ETL, modelos de datos, dashboards).

- ❖ Rama develop

Agrupar los cambios en desarrollo que aún están en validación. Es el punto de integración de las funcionalidades antes de pasar a producción.

- ❖ Ramas de característica (feature/*)

Se crean para cada tarea específica, por ejemplo:

- feature/grupo02-init

➤ feature/grupo02-init-integrante

Tras completarse, se integran en develop mediante pull request y revisión de código del líder del grupo

Este esquema garantiza trazabilidad de cambios, facilita el trabajo colaborativo y reduce el riesgo de introducir errores en el entorno estable.

- **Enfoque DevOps**

El proyecto adopta un enfoque DevOps para integrar las actividades de desarrollo (definición de modelo estrella, ETL, KPIs, dashboards) con las actividades de operación (despliegue en la nube, monitoreo, mantenimiento).

Los principios aplicados son:

- ❖ Automatización:
 - Ejecución automatizada de ETL en GCP (Dataproc).
 - Despliegue de estructuras de tablas en BigQuery mediante scripts versionados.
- ❖ Feedback continuo:
 - Validación de resultados de KPIs en entornos de prueba antes de publicarlos en el dashboard final.
 - Revisión de código (code review) antes de fusionar a develop o main.

- **Integración continua (CI)**

La integración continua se implementa mediante pipelines. Se ejecutan automáticamente las siguientes tareas:

1. Validación de código
 - ❖ Verificación de sintaxis en scripts SQL (BigQuery), Python (ETL, notebooks) y archivos de configuración.
 - ❖ Revisión de convenciones básicas (nombres de tablas, campos, formatos de fecha).
2. Pruebas de ETL en entorno de prueba
 - ❖ Carga de una muestra de datos en un dataset de prueba de BigQuery.
 - ❖ Ejecución de queries de validación (cuentas de registros, nulos, tipos de datos).
3. Validación del modelo de datos
 - ❖ Chequeo de integridad referencial (SK/FK) entre Fact_Diagnostico y las dimensiones (Dim_Tiempo, Dim_Paciente, Dim_Enfermedad, Dim_Ubigeo, etc.).
 - ❖ Validación de que el modelo soporte correctamente los KPIs definidos (ejecución de queries de ejemplo).

Solo si estas etapas son satisfactorias, los cambios se consideran aptos para promoción a entornos superiores (pre-producción / producción).

- **Reproducibilidad del entorno y de los análisis**

Para asegurar que los resultados (ETL, modelos, dashboards, KPIs) sean reproducibles, el proyecto define mecanismos en dos niveles: infraestructura y análisis de datos.

a) Reproducibilidad de infraestructura

- ❖ Infraestructura como código (IaC)

La configuración del entorno en GCP (datasets de BigQuery, buckets de Cloud Storage, clusters de Dataproc, cuentas de servicio) se define en archivos de configuración almacenados en el repositorio.

Esto permite recrear el entorno en otro proyecto o región de GCP de forma consistente.

- ❖ Scripts de despliegue versionados

Scripts para programar jobs de ETL (Cloud Composer, etc.).

Todos estos archivos forman parte del control de versiones.

b) Reproducibilidad de análisis y KPIs

- ❖ Notebooks y scripts parametrizados

Los análisis exploratorios (EDA), cálculos de KPIs y pruebas de consistencia se desarrollan en notebooks (Jupyter/Colab) o scripts Python/SQL parametrizados, versionados en Git.

De esta forma, cualquier miembro del equipo puede ejecutar los mismos pasos sobre la misma versión de los datos.

- ❖ Definiciones formales de KPIs

Cada KPI (tasa por 1000 hab., porcentaje de diagnósticos por región, tiempo entre diagnóstico y control, etc.) tiene:

- ➔ Definición formal, fórmula y unidad de medida.
- ➔ Query de referencia en BigQuery.

Esto asegura que todos los usuarios calculen e interpreten el indicador de la misma manera.

- ❖ Documentación y diccionario de datos

Se mantiene un diccionario de datos del modelo estrella (Fact y Dimensiones), con la descripción de cada campo, tipo de dato, dominio válido y fuente, permitiendo reproducir la construcción del DW y sus métricas.

12. CAPÍTULO I: EMPRESA SELECCIONADA

12.1. Generalidades de la empresa

12.1.1. Nombre o Razón Social

Razón social: Seguro Social de Salud (EsSalud)
RUC: 20131257750

12.1.2. Giro de la Empresa

Es un organismo público descentralizado del Estado peruano, con autonomía técnica, administrativa, económica, financiera, presupuestal y contable.
Su función principal es brindar servicios de seguridad social en salud, es decir:

- Prestaciones médicas: promoción, prevención, diagnóstico, tratamiento, rehabilitación.
- Prestaciones económicas y sociales vinculadas a riesgos humanos.

12.1.3. Ubicación de la Empresa

Su sede principal está en Lima, distrito de Jesús María, pero tiene red de establecimientos de salud distribuidos por todo el Perú: cobertura nacional.




Figura 1. Cobertura - EsSalud

En total, posee cerca de 400 establecimientos (hospitales generales, policlínicos, especializados) en diferentes regiones del país.

Además, forma parte del sistema estatal: sus líneas de coordinación institucional la conectan con el Ministerio de Salud, el Ministerio de Economía, y otros entes públicos.

12.1.4. Misión, Visión

12.1.4.1. Misión

“Brindamos prestaciones de salud, económicas y sociales a nuestros asegurados con una gestión eficiente e innovadora que garantiza la protección financiera de las prestaciones integrales.”

12.1.4.2. Visión

“Ser una institución moderna y en mejora continua, centrada en los asegurados, que garantiza el acceso a la seguridad social en salud con ética, oportunidad y calidad.”

12.1.4.3. Valores Institucionales

Según la entidad y su normativa interna (Código de Ética, manuales institucionales), algunos valores y principios que rigen la acción de EsSalud son:

- Solidaridad
- Universalidad
- Igualdad
- Integralidad
- Ética institucional

El Código de Ética / Código de Conducta de EsSalud recoge formalmente esos valores, principios, deberes, prohibiciones y el modelo de conducta esperada para sus funcionarios.

12.1.5. Productos y clientes

A. Productos

- **Prestaciones de Salud:** Comprenden los servicios médicos preventivos, asistenciales y de rehabilitación brindados en los diferentes niveles de atención, orientados a preservar y recuperar la salud del asegurado.
- **Prestaciones Económicas:** Incluyen subsidios por maternidad, lactancia, sepelio, incapacidad temporal y riesgos laborales, garantizando la protección financiera del asegurado.
- **Prestaciones Sociales:** Agrupan programas de bienestar social, atención al adulto mayor, rehabilitación física y laboral, y apoyo a personas con discapacidad.
- **Atención Primaria y Especializada:** Ofrecen consultas médicas, exámenes diagnósticos, hospitalización, telemedicina y servicios de alta complejidad en las redes asistenciales.
- **Programas Preventivos y de Promoción de la Salud:** Se enfocan en campañas de vacunación, detección temprana de enfermedades crónicas y educación sanitaria para fomentar hábitos saludables.
- **Gestión del Aseguramiento:** Comprende los procesos de registro, acreditación y control de cobertura de los asegurados y sus derechohabientes.


B. Clientes

- **Asegurados Regulares:** Trabajadores formales que aportan al sistema de seguridad social junto con sus derechohabientes, beneficiarios principales de los servicios de salud.
- **Pensionistas y Jubilados:** Personas retiradas del sistema laboral que mantienen acceso a los servicios médicos y económicos de EsSalud.
- **Trabajadores Independientes Asegurados:** Ciudadanos que realizan aportes voluntarios para acceder a las prestaciones de salud y protección económica.
- **Personas en Situación de Vulnerabilidad:** Adultos mayores, personas con discapacidad y grupos sociales que reciben atención prioritaria a través de programas sociales.
- **Empleadores y Empresas:** Instituciones públicas o privadas que contribuyen al financiamiento del seguro social y gestionan la afiliación de su personal.
- **Instituciones del Estado y Aliados Estratégicos:** Entidades gubernamentales que colaboran con EsSalud en campañas nacionales, convenios de cooperación y proyectos de salud pública.

12.2. Análisis del Negocio

12.2.1. Mapa de Procesos

Figura : Mapa de Proceso EsSalud




Fuente : EsSalud

12.2.2. Cadena de Valor

La cadena de valor de EsSalud representa cómo la institución organiza y articula sus procesos primarios y de soporte para cumplir su misión de brindar prestaciones integrales de salud, económicas y sociales, orientadas a la satisfacción del asegurado y del ciudadano.


Figura :Cadena de valor EsSalud




Fuente: EsSalud

12.2.3. Organigrama

El organigrama de EsSalud muestra una estructura jerárquica amplia y especializada que integra órganos de alta dirección, gerencias centrales, oficinas y subgerencias distribuidas por funciones estratégicas, asistenciales y de apoyo. Esta organización busca garantizar una gestión coordinada de los servicios de salud, aseguramiento, información y planificación institucional a nivel nacional.



12.2.4. Modelo CANVAS del Negocio



12.3. Diagnóstico Empresarial

12.3.1. Análisis FODA

Fortalezas	Oportunidades
Datos históricos institucionales de atenciones (emergencias, hospitalizaciones): Estos datos pueden ser la base para la construcción de modelos predictivos que permitan anticipar picos de demanda. Investigación previa en EsSalud sobre modelos predictivos para demanda en emergencias: Utilización de algoritmos de predicción que podrían integrarse con el análisis de la demanda futura. Procesos normados de distribución de camas hospitalarias: Manuales internos que, con ajustes, pueden optimizarse para prever la distribución de camas en función de la demanda anticipada. Soluciones digitales para el asegurado: Potencial para integrar plataformas de monitoreo de demanda y de gestión en tiempo real. Presencia de una red de establecimientos a nivel nacional: Ayuda a redistribuir la carga entre distintos centros, mejorando la capacidad de respuesta ante picos. Médicos reconocidos por su nivel de especialización y compromiso: Ayuda a optimizar los recursos humanos disponibles, lo que resulta clave ante incrementos de demanda.	Posibilidad de usar técnicas de series temporales y machine learning: Modelos como ARIMA/SARIMA para predecir picos de demanda, en especial en emergencias y hospitalización. Cooperación con entidades académicas: Generación de modelos de demanda oculta y proyectada, basados en estudios como el de estimación de demanda de servicios de salud. Impulso del gobierno para la transformación digital: Potencial para desarrollar herramientas predictivas a nivel nacional que ayuden a anticipar necesidades de infraestructura y recursos humanos. Crecimiento económico del país: Oportunidad de captar financiamiento o inversiones para fortalecer las infraestructuras y mejorar la capacidad de anticipación de demanda. Crecimiento de la población urbana: Aumenta la demanda de servicios médicos, lo que hace aún más urgente contar con una estrategia de anticipación de recursos.
Debilidades	Amenazas
Falta de sistematización e integración de datos históricos asistenciales: Los datos están disgregados y carecen de interoperabilidad, lo que dificulta su uso en modelos predictivos. Baja cultura institucional de planificación predictiva: Se enfoca más en respuestas reactivas ante la demanda que en la anticipación, lo que limita la capacidad de reacción ante picos inesperados. Recursos humanos rígidos: El personal no puede ajustarse rápidamente a aumentos en la demanda, lo que genera cuellos de botella y sobrecarga de trabajo. Procesos de asignación de camas no orientados a la anticipación: Los procedimientos actuales se basan en la distribución de camas de manera reactiva, sin contemplar una previsión a futuro que permita una	Eventos inesperados (epidemias, brotes, desastres naturales): Estos eventos pueden disparar de manera súbita la demanda de servicios de salud, lo que pone a prueba la capacidad de anticipación y respuesta. Incremento sostenido de demanda en emergencias: Ejemplo: en el Hospital Almenara, las esperas de hasta 96 horas por falta de camas revelan la incapacidad para manejar la demanda en picos. Violaciones de datos y ataques cibernéticos: La protección de los datos de los pacientes y la infraestructura digital es clave para el uso seguro y eficaz de los modelos predictivos y la gestión de demanda. Brecha digital en la población: Limita el acceso equitativo a servicios predictivos y digitales, lo que

mejor gestión ante aumentos repentinos de la demanda. Escasez presupuestal: La falta de recursos para mantener capacidad ociosa limita la posibilidad de prepararse para picos de demanda en situaciones de emergencia. Infraestructura y equipamiento médico deficiente: Las deficiencias en infraestructura y equipos dificultan la respuesta rápida ante situaciones que sobrepasen la capacidad establecida.	podría generar desigualdades en el manejo de la demanda. Leyes y normas que impactan la sostenibilidad financiera: Pueden restringir la inversión en nuevas tecnologías y recursos para mejorar la anticipación de demanda. Injerencia de terceros sobre la gestión institucional: Compromete la capacidad de respuesta eficiente y flexible ante situaciones que requieren decisiones rápidas.
---	--

A partir de este FODA, se revela que uno de los puntos críticos es la incapacidad para anticipar demanda y garantizar recursos (camas, personal, herramientas) con margen suficiente para picos.

12.3.2. Problema Encontrado

12.3.2.1. Descripción

Aunque EsSalud dispone de abundante información histórica de atenciones médicas, emergencias y hospitalizaciones, esta no se utiliza para modelar o prever la demanda futura. Los procesos actuales son reactivos, sin herramientas predictivas ni integración de sistemas que permitan analizar en tiempo real el uso de camas, personal o insumos.

La programación de recursos humanos, insumos y equipamiento se basa en consumo histórico, sin considerar proyecciones de demanda oculta o estacionalidad, generando deficiencias en la planificación hospitalaria.

12.3.2.2. Implicancias

- Saturación del sistema asistencial: ante picos de demanda, los hospitales no cuentan con camas libres ni personal suficiente.
- Falta de elasticidad operativa: no existen mecanismos automáticos que activen recursos de reserva (infraestructura, personal, equipamiento).
- Desconexión de sistemas: los datos clínicos, de ocupación y de personal se encuentran fragmentados entre distintos sistemas OLTP, dificultando la toma de decisiones integradas.
- Limitada capacidad de análisis predictivo: no hay un modelo de datos unificado ni herramientas de BI o machine learning aplicadas al planeamiento preventivo.

12.3.2.3. Consecuencias

- Retrasos críticos en la atención médica: los pacientes llegan a esperar más de 96 horas para hospitalización en hospitales como Almenara.
- Sobrecarga y estrés del personal médico: al no anticiparse picos de demanda, los turnos se extienden y disminuye la calidad de atención.
- Desabastecimiento de insumos y materiales médicos, afectando la continuidad de tratamientos.
- Ineficiencia operativa y aumento de costos institucionales, debido a decisiones tardías y medidas de emergencia improvisadas.
- Pérdida de confianza del asegurado y deterioro de la percepción pública de la institución.

12.4. Necesidades de Información y Decisiones Críticas

La anticipación de demanda afecta a toda la cadena de decisiones dentro de EsSalud. Aquí se muestran los distintos niveles de decisión y qué tipo de información necesitan.

Nivel	Tipo de decisiones	Necesidades de información / insumos requeridos
Estratégico	- Definir políticas institucionales para reservas de capacidad hospitalaria - Aprobar inversiones en infraestructura, sistemas y tecnología predictiva - Establecer criterios de distribución de recursos entre regiones o redes	- Proyecciones agregadas nacionales / regionales de demanda hospitalaria (camas, emergencias, internaciones) - Modelos de demanda futura (series temporales, escenarios) - Análisis de costos-beneficios de mantener reservas - Benchmarking con otros países u organismos de salud que usan predicción - Indicadores consolidados de ocupación, tasas de uso de camas históricas - Sensibilidad ante choques exógenos (epidemias, estacionales)
Táctico	- Planificación de recursos por hospitales o redes - Ajuste de dotaciones de personal, asignación de camas - Decidir cuándo activar reservas o medidas de contingencia - Priorización de mejoras en ciertos hospitales	- Pronósticos semanales/mensuales de ocupación por hospital - Niveles de camas libres / ocupadas - Indicadores de rotación de camas, días de estancia promedio - Datos de ingresos/egresos hospitalarios - Datos de personal (turnos, ausencias, capacidad ociosa) - Stock y consumo proyectado de insumos (medicamentos, equipos, reactivos) - Alertas automáticas de riesgo de saturación
Operativo	- Ajustes de última hora: cambio de turnos, reubicar pacientes, derivaciones - Asignación diaria de camas - Gestión del flujo de pacientes en emergencias y hospitalización - Monitoreo en tiempo real del uso de recursos	- Dashboard en tiempo real con camas disponibles / ocupadas - Listas de espera y backlog - Alertas inmediatas de congestión - Información de variables clave: tasa de llegada de pacientes, frecuencia de ingresos emergentes, urgencias - Estado de insumos críticos (disponibilidad actual) - Estado del personal asignado: cuántos disponibles en cada turno

12.5. KPI's iniciales

Nombre del KPI	Definición	Fórmula	Unidad	Frecuencia	Fuente de datos	Responsable
Promedio general de resultado por año	Mide la tendencia anual de los valores promedio de resultado.	Promedio(resultado de exámenes) agrupado por año.	Valor promedio por año	Anual	Datos Abiertos EsSalud, INEI	Unidad de Estadística Médica

Tasa de diagnósticos por grupo etario	Indica qué grupo etario concentra más diagnósticos.	$(\text{Cantidad de diagnósticos} / \text{Total de diagnósticos}) \times 100$	% del total de casos	Mes	Datos Abiertos EsSalud	Coordinación Epidemiológica
Departamento con mayor carga de diagnósticos	Identifica la región más afectada.	Suma(cantidad de diagnósticos) por región	Nº de diagnósticos	Mes	Datos Abiertos EsSalud, Ubigeo INEI	Gerencias Regionales
Variación porcentual anual del promedio de resultados	Mide si los niveles promedio de la enfermedad mejoran o empeoran cada año.	$(\text{Promedio año actual} - \text{Promedio año anterior}) / \text{Promedio año anterior} \times 100$	% de variación	Mes	Datos Abiertos EsSalud	Dirección de Prevención
Promedio de resultado por tipo de diabetes	Permite detectar si ciertos tipos presentan peores valores.	Promedio de resultado por enfermedad	Valor promedio	Mes	Datos hospitalarios	Coordinación de Control Médico
Distribución mensual de diagnósticos	Detecta estacionalidad o picos en diagnósticos.	Total (cantidad de diagnósticos)	Nº de diagnósticos por mes	Mes	Datos Abiertos EsSalud	Unidad de Estadística
Promedio ponderado de resultados por cantidad de diagnósticos	Integra la gravedad promedio considerando el peso de cada registro.	$\Sigma(\text{promedio resultado} \times \text{cantidad diagnósticos}) / \Sigma(\text{cantidad diagnósticos})$	Valor ponderado	Mes	Datos Abiertos EsSalud	Dirección de Epidemiología
Departamento con mejor control promedio	Identifica la región con mejores valores promedio de control.	Mínimo(promedio resultado)	Valor más bajo promedio	Mes	RRHH EsSalud, RENIPRESS	Jefatura de Recursos Humanos
Proporción de casos con complicaciones	Evalúa la gravedad de los diagnósticos según si hay complicaciones.	$(\text{Casos con complicación} / \text{Total de casos}) \times 100$	% de casos complicados	Mes	Datos Abiertos EsSalud	Gerencias de Red

Índice de concentración por grupo etario	Mide si los diagnósticos están concentrados en un grupo etario o distribuidos.	$\Sigma((\text{cantidad diagnósticos grupo} / \text{total diagnósticos})^2)$	Índice (0 = disperso, 1 = concentrado)	Mes	Datos Abiertos EsSalud, Ubigeo INEI	Dirección Estratégica
---	--	--	--	-----	-------------------------------------	-----------------------

13. CAPÍTULO II: DESARROLLO

13.1. Preguntas de Negocio

A partir de los problemas priorizados (incapacidad de anticipar demanda, falta de reserva, programación de personal, insumos, sistemas de información fragmentados), ahora definimos las principales preguntas de negocio que EsSalud deberá responder para diseñar soluciones.

Las preguntas están agrupadas por área relevante y ordenadas de mayor a menor prioridad dentro de cada área:

Área / dominio	Preguntas de negocio (prioritarias)
Demanda hospitalaria camas /	1. ¿Cuántas camas se van a necesitar diariamente, por hospital / red / región, durante las próximas 1-4 semanas, con un intervalo de confiabilidad (por ejemplo, percentil 90)? 2. ¿Cuál es la tasa de crecimiento esperado de demanda de internaciones por especialidad (medicina interna, cirugía, UCI) en los próximos meses? 3. ¿Cuál es el patrón estacional o de brotes que se ha dado históricamente en emergencias / ingresos hospitalarios? 4. ¿Cuántas camas de reserva deberían mantenerse para cubrir picos de demanda (porcentaje ideal)?
Personal de salud / recursos humanos	5. ¿Cuál debe ser la dotación diaria óptima de médicos, enfermeras y personal de soporte en cada hospital, dados los pronósticos de demanda? 6. ¿Cuántos profesionales adicionales se requieren para manejar escenarios de alta demanda (reservas de personal)? 7. ¿Qué variabilidad en ausencias (enfermedad, permisos, rotación) se debe considerar en la planificación? 8. ¿Cuántos turnos extras o personal de reemplazo se necesitan en escenarios de pico?

Insumos y herramientas	9. ¿Qué volumen de insumos críticos (medicamentos, consumibles, reactivos, dispositivos) será requerido en el horizonte previsto (meses), bajo demanda anticipada? 10. ¿Cuál debe ser el nivel de stock de seguridad para cubrir picos imprevistos? 11. ¿Cuántas herramientas / equipos de respaldo (ventiladores, bombas, monitores) se deben tener disponibles? 12. ¿Cuáles son los cuellos de botella en la cadena de suministro de insumos con base en demanda prevista?
Sistemas / datos / predicción	13. ¿Qué algoritmo de predicción (modelo estadístico / machine learning) ofrece mejor precisión para la demanda hospitalaria de EsSalud? 14. ¿Qué variables históricas (ingresos, estacionalidad, brotes, clima) son más predictivas? 15. ¿Qué grado de integración de datos (emergencia, hospitalización, camas, insumos) se requiere para alimentar el modelo en tiempo real? 16. ¿Cuál es el horizonte temporal óptimo de predicción (horas, días, semanas) para decisiones operativas / tácticas?
Gestión estratégica / institucional	17. ¿Cuál es el costo estimado de mantener reservas de capacidad (camas y personal) frente al costo de saturaciones y desbordes? 18. ¿Cuál es el retorno en cobertura y mejora en calidad al anticipar demanda vs. reaccionar? 19. ¿Qué políticas institucionales se deben emitir para garantizar que los hospitales adopten el modelo predictivo? 20. ¿En qué hospitales pilotos debe implementarse primero el sistema predictivo para escalar luego?

13.2. KPI's Definidos

Nombre del KPI	Definición	Fórmula	Unidad	Frecuencia	Fuente de datos	Responsable
Total de Atenciones	Cantidad total de diagnósticos	$\sum$ Atenciones registradas	Atenciones	Mensual	Datos Abiertos EsSalud	Gerencia Central de Prestaciones de


	o consultas registradas en el periodo seleccionado. Mide la carga operativa..					Salud
Pacientes Únicos Atendidos	Número de personas distintas que recibieron atención, sin importar cuántas veces fueron al hospital.	Número de pacientes distintos atendidos	Pacientes	Mensual	Datos Abiertos EsSalud	Oficina de Inteligencia e Información Sanitaria
Población con Diabetes	Cantidad de pacientes únicos que han sido diagnosticados con alguna variante del grupo Diabetes.	Número de pacientes con diagnóstico de Diabetes	Pacientes	Trimestral	Datos Abiertos EsSalud + CIE10	Dirección de Gestión Clínica
Población con Hipertensión	Cantidad de pacientes únicos diagnosticados con el grupo Hipertensión.	Número de pacientes con diagnóstico de Hipertensión	Pacientes	Trimestral	Datos Abiertos EsSalud + CIE10	Dirección de Gestión Clínica
Población con Obesidad	Cantidad de pacientes únicos diagnosticados con el grupo Obesidad.	Número de pacientes con diagnóstico de Obesidad	Pacientes	Trimestral	Datos Abiertos EsSalud + CIE10	Dirección de Gestión Clínica
Frecuencia de Visita por Paciente	Promedio de cuántas veces acude una persona al médico. Indica si son pacientes crónicos recurrentes.	Total de Atenciones / Pacientes Únicos Atendidos	Visitas / Paciente	Mensual	Datos Abiertos EsSalud	Gerencia de Planeamiento y Presupuesto
Tasa de Prevalencia de Diabetes	Porcentaje que representan los casos de	$(\text{Atenciones por Diabetes} / \text{Total de Atenciones}) \times 100$	Porcentaje (%)	Trimestral	Datos Abiertos EsSalud + CIE10	Oficina de Epidemiología

	diabetes respecto al total de atenciones generales.					
Atenciones en Adultos Mayores	Volumen de atenciones brindadas específicamente al grupo etario de riesgo (+60 años).	Número de atenciones en pacientes ≥ 60 años	Atenciones	Mensual	Datos Abiertos EsSalud	Gerencia del Adulto Mayor
Intensidad de Casos en Lima	Porcentaje de las atenciones que se concentran solo en el departamento de Lima respecto al país.	(Atenciones en Lima / Total de Atenciones Nacional) $\times 100$	Porcentaje (%)	Trimestral	Datos Abiertos EsSalud + Ubigeo (INEI / CEPLAN)	Gerencia de Planeamiento Estratégico
Ratio de Atención Femenina	Proporción de atenciones brindadas a mujeres. Útil para análisis por sexo.	(Atenciones a mujeres / Total de Atenciones) $\times 100$	Porcentaje (%)	Mensual	Datos Abiertos EsSalud	Oficina de Gestión de la Información

13.3. Modelo Conceptual Inicial

El modelo está centrado en la tabla de hechos Fact_Diagnostico, que almacena los eventos de diagnóstico registrados en las consultas externas de EsSalud.

Alrededor de ella se ubican las dimensiones descriptivas, que proporcionan el contexto para analizar los indicadores (KPI) desde distintas perspectivas: tiempo, paciente, médico, enfermedad, IPRESS, ubicación y procedimiento.



13.4. Inventario de fuentes OLTP

El inventario de fuentes OLTP tiene como propósito identificar y documentar los sistemas transaccionales internos o externos que generan los datos crudos esenciales para alimentar los modelos de análisis y predicción en EsSalud. Esto incluye conocer qué sistema captura cada tipo de dato (por ejemplo, consultas externas, codificación diagnóstica, infraestructura hospitalaria), qué unidad usuaria lo emplea, qué tipo de datos almacena (maestro o transaccional), la tecnología usada para su gestión, con qué frecuencia se actualiza, y cualquier observación relevante (latencia, fiabilidad, dependencia, etc.).

Este inventario es la base para diseñar las conexiones, las extracciones (ETL/ELT), los controles de calidad de datos y los procesos de integración que permitirán que los modelos predictivos (por ejemplo, de demanda hospitalaria) cuenten con datos consistentes, oportunos y verificables.

Sistema	Área usuaria	Tipo	Tecnología	Frecuencia actualización	Observaciones
Sistema de Planeamiento Estratégico – CEPLAN	Planeamiento Estratégico y Estadística	Maestro / referencia geográfica	Archivo XLS	Anual / Semestral (actualizan planes y ubigeos)	Incluye descripciones y metadatos de cada ubigeo; sirve como insumo referencial para consolidar datos de salud y otras áreas del Estado.
Sistema de Consultas Externas – Datos Abiertos EsSalud	Red hospitalaria / Consulta externa	Transaccional (registros médicos de atenciones y diagnósticos)	Archivos CSV	Diario	Incluye registros de exámenes de laboratorio en consultas externas con diagnóstico de diabetes, hipertensión y obesidad (2020–2024).
Sistema de Codificación Geográfica – Ubigeo (INEI)	Planeamiento / Estadística	Maestro (catálogo)	Archivo CSV	Eventual / según necesidad	Contiene códigos y descripciones de distrito, provincia y departamento; se usa como referencia estándar para enlazar datos de salud con ubicación geográfica oficial.

Sistema de Clasificación Internacional de Enfermedades – CIE10	Áreas médicas / estadística	Maestro	Archivo CSV	Eventual / según necesidad	Contiene el código y descripción de enfermedades según la Clasificación Internacional de Enfermedades (CIE-10).
--	-----------------------------	---------	-------------	----------------------------	---

13.5. Estrategia de Migración a la Nube

13.5.1. Nube elegida

La migración a la nube para el proyecto de Inteligencia de Negocios de EsSalud se basa en la necesidad de integrar información fragmentada, reducir tiempos de procesamiento, habilitar analítica avanzada y garantizar escalabilidad. El entorno cloud elegido es Google Cloud Platform (GCP) por su fortaleza nativa en analítica y Big Data.

13.5.1.1. Descripción

Google Cloud Platform (GCP) es una plataforma de servicios cloud que permite ejecutar cargas de trabajo de almacenamiento, procesamiento, integración, análisis de datos y visualización con alto rendimiento, elasticidad y seguridad.

Para este proyecto, GCP ofrece:

- Cloud Storage para el Data Lake.
- Dataproc o Dataflow para procesamiento ETL/ELT.
- BigQuery como Data Warehouse columnar serverless.
- Looker Studio para dashboards e inteligencia de negocios.

GCP es especialmente adecuado para proyectos de datos masivos debido a su arquitectura distribuida basada en Dremel, Colossus y Borg, lo que permite escalabilidad casi ilimitada y consultas en segundos incluso sobre terabytes.

13.5.1.2. Entorno en la nube

El entorno de GCP ofrece numerosos servicios para diferentes necesidades en proyectos de amplia gama, en el siguiente cuadro describimos las más importantes para el proyecto del sistema de inteligencia de negocios para EsSalud.

Fase	Servicio	Función	Equivalencias (AWS/Azure)
Ingesta / Data Lake	Cloud Storage	Almacena datos OLTP crudos (Bronce). Maneja archivos CSV/XLS recibidos diariamente.	S3 / Azure Blob
Procesamiento ETL	Dataproc	Procesa datos mediante Spark en cluster administrado (batch).	EMR / Synapse Spark
Data Warehouse	BigQuery	Almacén analítico serverless. Modelos estrella, KPIs y análisis.	Redshift / Azure Synapse SQL
Orquestación	Cloud Functions	Automatiza el pipeline mediante ejecución de funciones serverless basadas en eventos (disparadores por tiempo, carga de archivos o mensajes)..	AWS Lambda / Azure Functions
Seguridad	IAM + Service Accounts	Manejo de roles, permisos granulares y autenticación.	IAM AWS / Azure AD RBAC

13.5.1.3. Justificación de elección
Se evaluaron las nubes GCP, AWS y Azure según criterios clave para el proyecto EsSalud.

Característica	Google Cloud Platform (GCP)	Amazon Web Services (AWS)	Microsoft Azure	GANADOR
1. Analítica y Big Data nativa	BigQuery: DW totalmente serverless, separación de cómputo/almacenamiento, consultas muy rápidas sobre grandes volúmenes.	Athena + Redshift: Athena consulta en S3; Redshift requiere nodos y cierta administración.	Synapse Analytics: SQL on-demand + pool provisionado; buen rendimiento pero requiere configuración.	GCP: BigQuery es serverless y ofrece análisis a gran escala sin administrar infraestructura.
2. Pricing y costo por procesamiento	BigQuery: pago por TB consultado y almacenamiento económico; no requiere instancias.	Redshift: costo por nodos provisionados; Redshift Serverless más caro.	Synapse: precio por DWU; requiere pausar o ajustar capacidad.	GCP: El modelo por consulta reduce costos y elimina la necesidad de provisionar servidores.
3. Seguridad e IAM	IAM + Service Accounts: permisos granulares y auditoría centralizada.	AWS IAM: muy robusto y con políticas detalladas.	Azure AD + RBAC: fuerte integración corporativa con AD.	Empate: cumplen estándares altos y ofrecen IAM avanzado.
4. Servicios ETL/ELT	Dataproc: clúster administrado con autoscaling para procesamiento batch Bronce → Plata → Oro. Alta flexibilidad y control del procesamiento distribuido.	Amazon EMR (Spark): procesamiento distribuido potente, pero con mayor complejidad de configuración y costos operativos.	Azure Synapse Spark: Spark integrado a Synapse, buen rendimiento, pero menos flexible y con mayor sobrecarga de configuración.	GCP: Dataproc ofrece Spark administrado con menor complejidad y costos controlados..
5. Ecosistema de ML	Vertex AI: ML unificado, AutoML, BigQuery ML integrado y pipelines MLOps.	SageMaker: muy completo, pero más caro y complejo.	Azure ML: fácil de usar, pero menos robusto en producción.	GCP: Vertex AI integra ML y DW de forma nativa y simplifica el despliegue.
6. Orquestación de pipelines de datos	Cloud Functions: ejecución de funciones serverless para automatizar pipelines ETL ligeros basados en eventos.	MWAA (Managed Workflows for Apache Airflow) + Step Functions: Airflow administrado pero con mayor complejidad de configuración (VPC, IAM, costos). Step Functions es potente pero más orientado a microservicios que a analítica de datos.	Azure Data Factory: orquestador visual con pipelines ETL/ELT integrados a Synapse y Data Lake. Muy potente, pero menos flexible que Airflow para flujos complejos y lógica avanzada.	GCP: Cloud Composer ofrece orquestación estándar con Airflow, menor complejidad operativa y mejor integración nativa con servicios analíticos.

Según nuestro análisis comparativo, GCP es la mejor plataforma para el caso EsSalud porque:

- Ofrece analítica avanzada nativa, sin necesidad de administrar servidores.
- BigQuery procesa millones de registros en segundos.
- Dataproc permite pipelines escalables con costo optimizado.
- Looker Studio se integra directamente y sin costo adicional.
- Su esquema de precios por consulta y almacenamiento particionado reduce costos totales.
- Alinea las necesidades del proyecto: datos masivos, rapidez, seguridad y dashboards accesibles.

13.5.2. Comparación

13.5.2.1. Características principales

Comparamos las características de una infraestructura on-premise vs una infraestructura en la nube GCP mediante el siguiente cuadro comparativo:

Dimensión	Local (On-Premise)	Cloud (GCP)
Escalabilidad	Limitada por hardware	Ilimitada y automática
Mantenimiento	Requiere personal especializado	Google gestiona infraestructura
Seguridad	Depende del datacenter	IAM, cifrado automático, compliance
Velocidad de procesamiento	Lento/moderado	BigQuery para procesamiento masivo y rápido
Capacidad de integración	Baja	APIs, conectores, ETL serverless
Costos iniciales	Muy altos (CAPEX)	Bajos (OPEX)
Disponibilidad	Depende de hardware	SLA 99.99%

13.5.2.2. Costos

Realizamos una estimación en base a los datos que tenemos de EsSalud.

USO DE SUSCRIPCIÓN

La suscripción a Google Cloud Platform (GCP) se basa en un modelo de pago por uso (pay-as-you-go), lo que permite a las organizaciones consumir únicamente los recursos que utilizan, sin necesidad de inversiones iniciales en infraestructura. Este modelo resulta especialmente adecuado para proyectos de analítica de datos y Business Intelligence, como el caso del proyecto EsSalud, donde los volúmenes de datos y la carga de procesamiento pueden variar en el tiempo.

La plataforma ofrece servicios nativos serverless y administrados, como BigQuery, Cloud Storage y Looker Studio, que reducen la sobrecarga operativa y los costos asociados a la administración de servidores. Asimismo, GCP integra herramientas avanzadas de orquestación (Cloud Composer) y procesamiento distribuido (Dataproc), permitiendo automatizar pipelines de datos complejos con alta escalabilidad y disponibilidad.

En conjunto, la suscripción a GCP proporciona flexibilidad, escalabilidad automática, optimización de costos y alta integración entre servicios, convirtiéndola en una alternativa eficiente para proyectos de analítica y toma de decisiones basadas en datos.

Matriz de costo de los servicio de GCP

Servicio	Rol en la arquitectura	Tipo de costo	Descripción del costo
Cloud Storage	Almacenamiento de datos en capas Bronce y Plata y Oro	Pago por GB almacenado y transferencia	Costo bajo por almacenamiento de archivos CSV originales y procesados. Ideal para data lakes. No requiere servidores ni administración adicional.
Dataproc	Procesamiento distribuido Bronce → Plata → oro(Spark)	Pago por nodo/hora + recursos de cómputo	Se paga solo mientras el clúster está activo. Permite crear clústeres temporales para reducir costos en cargas de procesamiento por lotes.
BigQuery	Data Warehouse analítico (Plata y Oro)	Pago por TB consultado y almacenamiento	Modelo serverless. No se pagan instancias. El costo depende del volumen de datos consultados y almacenados, optimizando el gasto en analítica.
Cloud Functions	Automatización y ejecución de lógica de orquestación ligera	Pago por invocaciones, tiempo de ejecución y memoria	Servicio serverless orientado a eventos. Solo se paga cuando la función se ejecuta. Ideal para disparar procesos ETL, validaciones y cargas automáticas con bajo costo operativo.

Datos base del proyecto:

- 15 GB mensuales de datos nuevos (CSV/XLS).
- 100 GB de almacenamiento total (Bronce + Plata + Oro).
- 2 TB de consultas mensuales en BigQuery.
- 1 cluster Dataproc temporal 1 hora diaria.

Servicio	Costo mensual	Costo anual
Cloud Storage (100 GB + 15 GB/mes)	2.0	24.0
BigQuery almacenamiento (100 GB)	2.0 (100 GB * \$0.02/GB)	24.0
BigQuery consultas (2 TB/mes → \$5/TB)	12.50 (2 TB × \$6.25/TB)	150

Dataprocc (cluster 1h diaria n1-standard-4)	24 (8 vCPUs× \$0.01× 30 h)	288
Cloud Funtions (mínimo ambiente)	0	0
IAM y seguridad	0	0
TOTAL	≈ USD 110.5/mes	≈ USD 1,326/año

Estrategias de optimización de costos:

- Autoscaling en Dataprocc: Permite que los recursos (nodos o workers) aumenten o disminuyan automáticamente según la carga del proceso ETL, evitando pagar por capacidad ociosa y garantizando procesamiento eficiente en picos.
- Migrar datos históricos a Nearline/Coldline en Cloud Storage: Mueve información poco consultada a clases de almacenamiento más económicas. Nearline es ideal para acceso mensual, Coldline para acceso trimestral, con tarifas mucho más bajas que el almacenamiento estándar.
- Particionar tablas de BigQuery (fecha, región): Organiza las tablas en secciones lógicas según una columna. BigQuery solo escanea las particiones necesarias, reduciendo el volumen procesado y el costo de consulta.
- Utilizar clústeres ephemeral de Dataprocc (por hora): Son clústeres temporales que se crean al inicio del job y se destruyen al finalizar. Esto reduce costos significativamente al evitar mantener servidores activos todo el día.
- Reducir TB consultados mediante materialized views: Las vistas materializadas almacenan la consulta preprocesada. BigQuery analiza solo los cambios incrementales, disminuyendo la cantidad de datos leídos en consultas repetitivas.
- Aplicar compresión y eliminación de duplicados en el Data Lake: Comprimir archivos (Parquet, Avro, gzip) y eliminar duplicados reduce el tamaño almacenado y el volumen leído en ETL, acelerando los procesos y disminuyendo costos de almacenamiento y escaneo.

USO GRATUITO DE \$300 DE CRÉDITOS POR LOS PRIMEROS 12 MESES

Google Cloud Platform ofrece un Free Tier que permite probar, desarrollar y validar arquitecturas sin costo inicial. Este esquema se divide en dos componentes principales:

- Disponible para nuevos usuarios.
- Crédito válido por 12 meses desde la activación.
- Puede utilizarse en casi todos los servicios de GCP (incluidos Dataprocc y Cloud Composer).
- Ideal para pruebas de arquitectura, ejecución de pipelines ETL y validación de dashboards BI.
- Al agotarse el crédito o vencido el plazo, no se generan cargos automáticamente sin autorización explícita.

Uso recomendado en el proyecto


- Pruebas de Dataprocc (Spark).
- Ejecución inicial de Cloud Composer.
- Simulación del flujo Bronce → Plata → Oro.

Servicio	Costo mensual
Cloud Storage (100 GB + 15 GB/mes)	0
BigQuery almacenamiento (100 GB)	0
BigQuery consultas (2 TB/mes → \$5/TB)	0
Dataproc (cluster 1h diaria n1-standard-4)	0
Cloud Functions (mínimo ambiente)	0
IAM y seguridad	0
TOTAL	≈ USD 0/mes

14. CAPÍTULO III: ARQUITECTURA CLOUD Y DISEÑO DE SOLUCIÓN

14.1. Arquitectura General en GCP

La solución propuesta se basa en una arquitectura cloud-native implementada sobre Google Cloud Platform (GCP), diseñada para soportar el procesamiento, almacenamiento y análisis de grandes volúmenes de datos epidemiológicos relacionados con enfermedades no transmisibles (ENT) en EsSalud. Esta arquitectura sigue principios modernos de escalabilidad, desacoplamiento, automatización y pago por uso, los cuales resultan adecuados para entornos institucionales con restricciones presupuestales y alta variabilidad en la carga de trabajo.



La arquitectura general se estructura en cuatro capas principales:

- Capa de almacenamiento (Data Lake)
- Capa de procesamiento (ETL)
- Capa analítica (Data Warehouse)
- Capa de visualización (Dashboard)

Cada una de estas capas cumple una función específica y se integra de forma desacoplada, permitiendo escalar o modificar componentes sin afectar el funcionamiento global del sistema.

14.2. Descripción de Componentes

14.2.1. Data Lake

El Data Lake se implementa utilizando Google Cloud Storage, el cual actúa como repositorio central de datos estructurados provenientes de diversas fuentes, principalmente archivos CSV y XLSX relacionados con diagnósticos, atenciones y variables demográficas.

El almacenamiento se organiza siguiendo el patrón Medallion, dividiendo los datos en tres zonas claramente definidas:

- Zona Bronce:

Contiene los datos crudos tal como son obtenidos desde las fuentes originales, sin ningún tipo de transformación. Esta zona preserva el formato original de los archivos y permite la trazabilidad y reprocesamiento futuro.

- Zona Plata:

Almacena los datos previamente limpiados, estandarizados y normalizados. En esta etapa se corrigen inconsistencias, se unifican formatos y se integran variables demográficas y geográficas.

- Zona Oro:

Contiene los datos consolidados y agregados, listos para ser consumidos por el Data Warehouse y las herramientas de inteligencia de negocios.

Esta separación por capas permite un control claro del ciclo de vida del dato y mejora la calidad de la información utilizada para análisis.

14.2.2. ETL

El proceso ETL (Extracción, Transformación y Carga) constituye el núcleo operativo de la arquitectura propuesta, ya que permite convertir datos heterogéneos y crudos en información estructurada y lista para el análisis epidemiológico. En este proyecto, el ETL se diseña bajo un enfoque automatizado y orientado a eventos, aprovechando servicios administrados de Google Cloud Platform.

La activación del proceso ETL se produce automáticamente cuando se carga un nuevo archivo en la zona Bronce del Data Lake (Cloud Storage). Este evento es detectado por Cloud Functions, que actúa como un mecanismo de escucha. Posteriormente, la función invoca un servicio desplegado en Cloud Run, el cual cumple el rol de orquestador ligero del pipeline.

Cloud Run se encarga de iniciar el job correspondiente en Google Cloud Dataproc, donde se ejecutan los procesos de transformación utilizando Apache Spark. Esta arquitectura permite desacoplar la lógica de orquestación del procesamiento distribuido, reduciendo la complejidad del sistema y evitando el uso de herramientas de orquestación más pesadas.

Durante la fase de transformación, se aplican reglas orientadas al análisis de enfermedades no transmisibles, tales como:

- Limpieza de registros incompletos o inconsistentes
- Normalización de formatos de fechas y unidades de medida
- Estandarización de diagnósticos clínicos mediante códigos CIE-10
- Integración de datos clínicos con información demográfica y geográfica
- Generación de atributos derivados relevantes para el análisis epidemiológico

Los datos resultantes se almacenan en la zona Plata y posteriormente en la zona Oro del Data Lake, utilizando formatos optimizados para análisis, lo que facilita su posterior carga al Data Warehouse.

14.2.3. Data Warehouse

El Data Warehouse de la solución se implementa utilizando BigQuery, el servicio de analítica serverless de Google Cloud Platform. BigQuery permite almacenar y consultar grandes volúmenes de datos sin necesidad de administrar infraestructura, lo cual resulta especialmente adecuado para instituciones públicas como EsSalud.

En esta capa se almacenan los datos consolidados de la zona Oro, organizados bajo un modelo dimensional en esquema estrella, diseñado para soportar consultas analíticas relacionadas con la vigilancia epidemiológica de enfermedades no transmisibles. Este modelo facilita el cálculo de indicadores clave como número de diagnósticos, distribución geográfica de casos y tendencias temporales.

Entre las principales ventajas de BigQuery dentro de la arquitectura se destacan:

- Capacidad de procesar millones de registros en segundos
- Escalabilidad automática ante incrementos de carga
- Integración nativa con herramientas de inteligencia de negocios
- Modelo de costos basado en almacenamiento y volumen de datos consultados

El Data Warehouse actúa como la fuente central de información analítica, garantizando consistencia, rendimiento y disponibilidad para los procesos de toma de decisiones.

14.2.4. Dashboard

La capa de visualización se implementa mediante Power BI, herramienta de inteligencia de negocios ampliamente utilizada para el análisis y presentación de información. Power BI se conecta directamente a BigQuery a través de su conector nativo, lo que permite consumir los datos del Data Warehouse sin necesidad de replicarlos localmente.

Los dashboards desarrollados están orientados a distintos niveles de análisis y gestión dentro de EsSalud, permitiendo:

- Monitorear indicadores epidemiológicos generales a nivel nacional
- Analizar la situación específica de Lima Metropolitana
- Evaluar de forma detallada cada enfermedad no transmisible (diabetes, hipertensión y obesidad)

Las visualizaciones incluyen gráficos de líneas, barras, tablas dinámicas y mapas, facilitando la identificación de patrones, tendencias y zonas de mayor riesgo. De esta manera, el dashboard analítico transforma los datos procesados en información clara y accionable, apoyando la toma de decisiones estratégicas, tácticas y operativas.

14.3. Diseño de Seguridad y Roles

La seguridad de la información es un aspecto crítico en soluciones de inteligencia de datos aplicadas al sector salud, debido a la sensibilidad de los datos clínicos y epidemiológicos que se procesan. En este proyecto, el diseño de seguridad se basa en los principios de mínimo privilegio, separación de responsabilidades y defensa en profundidad, aprovechando los mecanismos nativos de Google Cloud Platform.

La arquitectura propuesta incorpora controles de acceso a nivel de proyecto, servicios y datos, garantizando que cada componente del sistema solo tenga los permisos estrictamente necesarios para cumplir su función. Asimismo, se considera la trazabilidad de accesos y operaciones como un elemento clave para auditoría y futuras ampliaciones institucionales.

14.3.1. Control de Acceso IAM

El control de accesos se implementa mediante Identity and Access Management (IAM) de Google Cloud Platform, el cual permite definir de manera centralizada qué identidades pueden acceder a qué recursos y con qué nivel de permiso.

En la solución propuesta, se definen roles diferenciados según el tipo de usuario y componente de la arquitectura:

- Roles de administración: responsables de la gestión del proyecto GCP, creación de recursos y configuración de políticas de seguridad.
- Roles de procesamiento de datos: asignados a servicios como Cloud Functions, Cloud Run y Dataproc, con permisos específicos para leer desde Cloud Storage, ejecutar jobs de procesamiento y escribir resultados en BigQuery.
- Roles analíticos: orientados a usuarios de negocio y analistas, con acceso de solo lectura a los datasets del Data Warehouse en BigQuery.
- Roles de visualización: utilizados por Power BI para consultar datos analíticos sin capacidad de modificación.

La separación de roles permite reducir el riesgo de accesos no autorizados y facilita la auditoría de actividades. Además, se emplean cuentas de servicio para la comunicación entre servicios cloud, evitando el uso de credenciales personales en procesos automatizados.

Este enfoque asegura que el acceso a los datos epidemiológicos se encuentre controlado, alineado con buenas prácticas de seguridad y preparado para un entorno institucional como EsSalud.

14.3.2. Almacenamiento de credenciales

El almacenamiento y manejo de credenciales se diseña para evitar la exposición de información sensible, como claves de acceso, tokens o configuraciones críticas. En la arquitectura propuesta, no se almacenan credenciales directamente en el código fuente ni en los repositorios de versionamiento.

Para los componentes desplegados en Cloud Run y Cloud Functions, se utilizan cuentas de servicio gestionadas por GCP, las cuales heredan permisos IAM de manera segura y transparente. Esto elimina la necesidad de manejar usuarios y contraseñas de forma explícita.

Cuando es necesario manejar parámetros de configuración sensibles, estos se gestionan mediante variables de entorno o servicios de almacenamiento seguro proporcionados por la plataforma, asegurando que la información crítica no quede expuesta en texto plano.

Este enfoque reduce significativamente el riesgo de filtración de credenciales, facilita la rotación de permisos y cumple con estándares modernos de seguridad en entornos cloud.

14.4. Estructura de Carpetas y Versionamiento en Github

El versionamiento del proyecto se realiza utilizando GitHub como repositorio central de código, configuraciones y documentación. Una estructura de carpetas clara y consistente permite mejorar la mantenibilidad del proyecto, facilitar el trabajo colaborativo y garantizar la trazabilidad de los cambios realizados durante el desarrollo.

La organización del repositorio se define de acuerdo con los componentes principales de la solución:

- Carpeta de scripts ETL (Spark / PySpark)
- Carpeta de funciones de orquestación (Cloud Functions / Cloud Run)

- Carpeta de scripts SQL y definiciones del Data Warehouse
- Carpeta de documentación técnica y diagramas de arquitectura

Esta separación lógica permite identificar rápidamente la función de cada archivo y simplifica futuras extensiones del proyecto.

14.4.1. Flujo GitFlow

Para el control de versiones se adopta el modelo GitFlow, el cual define un flujo estructurado de ramas que facilita el desarrollo ordenado y la integración continua.

El flujo utilizado contempla las siguientes ramas principales:

- main: contiene la versión estable del proyecto, correspondiente a entregables finales o versiones validadas.
- develop: integra los cambios en desarrollo y sirve como base para nuevas funcionalidades.
- feature/: ramas destinadas al desarrollo de funcionalidades específicas, como mejoras en el ETL, nuevos indicadores o ajustes en el modelo de datos.
- hotfix/: ramas utilizadas para correcciones rápidas sobre versiones estables.


El uso de GitFlow permite mantener un historial claro de cambios, reducir conflictos entre desarrolladores y asegurar que solo código validado llegue a la rama principal. Además, facilita la trazabilidad entre requerimientos, implementaciones y resultados obtenidos, aspecto clave en proyectos académicos y profesionales.

15. CAPÍTULO IV: PROCESO ETL EN GOOGLE CLOUD PLATFORM

15.1. Diagrama de Flujo del Proceso ETL

El proceso ETL implementado en este proyecto sigue un flujo automatizado, desacoplado y orientado a eventos, diseñado para transformar datos crudos de EsSalud en información analítica lista para su consumo en dashboards epidemiológicos. Aunque el diagrama no se representa gráficamente en este apartado, el flujo lógico del proceso se describe de manera secuencial a continuación:

- Carga de archivos CSV/XLS en el bucket de Cloud Storage (zona Bronce).
- Detección del evento de carga mediante Cloud Functions.
- Invocación del servicio de orquestación desplegado en Cloud Run.
- Ejecución del job ETL en Google Cloud Dataproc utilizando Apache Spark.
- Transformación de los datos desde la capa Bronce hacia Plata.
- Generación de estructuras analíticas y agregaciones en la capa Oro.
- Carga final de los datos consolidados en BigQuery.



Este flujo permite que el sistema responda automáticamente ante la llegada de nuevos datos, eliminando la intervención manual y garantizando la actualización continua de la información epidemiológica.

El diseño del flujo ETL se encuentra alineado con el patrón Medallion Architecture, donde cada etapa cumple una función clara dentro del ciclo de vida del dato, desde su estado crudo hasta su forma analítica certificada.

15.2. Scripts de Extracción, Transformación y Carga

Los scripts ETL fueron desarrollados en Python utilizando PySpark, ejecutándose sobre clústeres temporales de Google Cloud Dataproc. Esta elección permite aprovechar procesamiento distribuido, manejo eficiente de grandes volúmenes de datos y una integración nativa con Cloud Storage y BigQuery.

Los scripts siguen una estructura modular, donde cada fase del ETL se encuentra claramente definida, facilitando su mantenimiento, reutilización y futura extensión.

15.2.1. Extracción

La fase de extracción tiene como objetivo leer los datos desde sus fuentes originales sin alterar su contenido, preservando la fidelidad de la información y asegurando la trazabilidad.

En el proceso implementado:

- Los archivos se leen directamente desde Cloud Storage (zona Bronce).
- Se soportan formatos estructurados como CSV y XLSX.
- Los datos se cargan en DataFrames de Spark manteniendo la estructura original.
- Se validan aspectos básicos como la existencia de columnas esperadas y tipos de datos generales.

Durante esta etapa no se aplican transformaciones semánticas profundas, ya que el propósito principal es garantizar que los datos de origen estén disponibles para su posterior procesamiento. Esta estrategia permite reprocesar información histórica en caso de cambios en las reglas de negocio.

15.2.2. Transformación

La fase de transformación constituye el núcleo lógico del ETL y es donde se aplican las reglas de negocio definidas para la vigilancia epidemiológica de enfermedades no transmisibles. Estas transformaciones se implementan mediante operaciones distribuidas de PySpark, lo que garantiza eficiencia y escalabilidad.

Las principales transformaciones aplicadas incluyen:

- Limpieza de registros con valores nulos o inconsistentes en campos críticos.
- Normalización de formatos de fecha para análisis temporal.
- Estandarización de diagnósticos clínicos mediante códigos CIE-10.
- Generación de atributos derivados, como grupo etario del paciente.
- Integración de información clínica con datos demográficos y geográficos.
- Eliminación de duplicados y validación de consistencia lógica.

Adicionalmente, durante esta fase se preparan las estructuras necesarias para el modelo dimensional, generando claves sustitutas y separando la información en entidades conceptuales como pacientes, enfermedades, tiempo y ubicación geográfica.

Los resultados de esta fase se almacenan en la zona Plata, utilizando formatos columnar optimizados como Parquet, lo que reduce costos de almacenamiento y mejora el rendimiento de las consultas posteriores.

15.2.3. Carga

En la fase de carga, los datos ya transformados y consolidados se insertan en la zona Oro y posteriormente en el Data Warehouse de BigQuery. Esta etapa incluye:

- Creación y actualización de tablas dimensionales y de hechos.
- Inserción incremental de nuevos registros.
- Aplicación de particionamiento y clustering en BigQuery.
- Validación de relaciones entre hechos y dimensiones.

La carga se realiza de manera controlada, garantizando la integridad referencial y la consistencia del modelo analítico. Una vez completada esta fase, los datos quedan disponibles para su consumo inmediato por Power BI.

15.3. Automatización del ETL

La automatización del proceso ETL es un componente clave de la solución propuesta, ya que permite operar el sistema sin intervención manual y asegurar la actualización continua de los indicadores epidemiológicos.

A diferencia de enfoques tradicionales basados en ejecución manual o planificación rígida, este proyecto adopta un modelo event-driven, donde el ETL se ejecuta únicamente cuando existen nuevos datos disponibles, optimizando costos y recursos de cómputo.

15.3.1. Orquestación con Cloud Run y Cloud Functions

La orquestación del ETL se implementa mediante la combinación de Cloud Functions y Cloud Run, reemplazando herramientas más complejas como Cloud Composer.

El flujo de orquestación es el siguiente:

- Cloud Functions detecta la carga de un nuevo archivo en Cloud Storage.
- La función valida el evento y dispara una solicitud HTTP hacia Cloud Run.
- Cloud Run ejecuta un servicio containerizado que coordina el job ETL.
- El servicio lanza el clúster Dataproc y ejecuta el script PySpark.
- Finalizado el proceso, el clúster se destruye automáticamente.

Este enfoque presenta múltiples ventajas:

- Reducción de costos al usar servicios serverless.
- Menor complejidad operativa.
- Escalabilidad automática según la carga.
- Mayor resiliencia ante fallos puntuales.

La automatización garantiza que la plataforma funcione de manera continua y confiable, constituyendo una base sólida para futuras extensiones hacia procesamiento más frecuente o casi en tiempo real.

15.4. Ejecución del Proceso ETL

La ejecución del proceso ETL permite validar en un entorno real el funcionamiento de la arquitectura propuesta, asegurando que los datos fluyan correctamente desde su estado original hasta su forma analítica final. Esta etapa es fundamental para verificar la calidad, consistencia y utilidad de la información generada.

El proceso de ejecución se desarrolla de manera automatizada, activándose cada vez que se detecta la carga de nuevos archivos en la zona Bronce del Data Lake.

15.4.1. Análisis inicial de datos

Antes de ejecutar el proceso ETL, se realiza un análisis inicial de los datos de origen con el objetivo de comprender su estructura, calidad y posibles inconsistencias. Los archivos provenientes de EsSalud presentan características propias de sistemas operacionales, tales como:

- Presencia de valores nulos en campos clínicos y demográficos.
- Inconsistencias en formatos de fechas.
- Duplicidad de registros por múltiples atenciones del mismo paciente.
- Diferencias en la codificación de diagnósticos.

Este análisis inicial permite definir reglas de limpieza y transformación adecuadas, asegurando que los procesos posteriores se encuentren alineados con los objetivos analíticos del proyecto.

15.4.2. Ejecución del proceso automatizado del ETL

Una vez cargados los archivos en Cloud Storage, el proceso ETL se ejecuta de manera automática siguiendo el flujo definido en la arquitectura:

- Cloud Functions detecta el evento de carga del archivo.
- Cloud Run inicia el proceso de orquestación.
- Dataproc ejecuta el script PySpark de extracción, transformación y carga.

Durante la ejecución, el clúster Dataproc procesa los datos de forma distribuida, aplicando las transformaciones definidas y generando los datasets correspondientes a las capas Plata y Oro. El proceso se completa sin intervención manual, demostrando la eficiencia del enfoque event-driven.

Al finalizar el job, los datos quedan disponibles en BigQuery para su análisis inmediato desde Power BI.

15.4.3. Análisis final de datos

Posterior a la ejecución del ETL, se realiza un análisis final de los datos transformados con el objetivo de verificar que las reglas de negocio se hayan aplicado correctamente. En esta etapa se observa:

- Homogeneización de formatos y codificaciones.
- Eliminación de registros inválidos o incompletos.
- Generación correcta de dimensiones y tablas de hechos.
- Mejora significativa en la consistencia y calidad de los datos.

Los datos resultantes permiten realizar análisis temporales, geográficos y epidemiológicos de manera confiable, algo que no era posible con los datos en su estado original.

15.4.4. Comparación de la situación inicial y situación final de los datos

La comparación entre la situación inicial y final de los datos evidencia el valor del proceso ETL implementado. Antes del ETL, la información se encontraba dispersa, con inconsistencias y limitada capacidad analítica. Después del ETL, los datos presentan:

- Estructura uniforme y estandarizada.
- Integración entre información clínica y demográfica.
- Reducción de duplicados y errores.

- Preparación adecuada para análisis OLAP y visualización.

Esta transformación permite que la información pase de un enfoque meramente operativo a uno analítico, facilitando la toma de decisiones basadas en datos.

15.5. Bitácora Técnica de Ejecución

La bitácora técnica de ejecución constituye un mecanismo de control y seguimiento del proceso ETL, permitiendo registrar eventos relevantes, identificar fallos y validar la correcta ejecución del pipeline.

Esta bitácora resulta fundamental para garantizar la trazabilidad del proceso, especialmente en entornos donde la confiabilidad de los datos es crítica, como el sector salud

15.5.1. Registro de ejecución

El registro de ejecución documenta cada corrida del proceso ETL, incluyendo información como:

- Fecha y hora de inicio y fin del proceso.
- Identificación del archivo procesado.
- Estado de la ejecución (exitosa o fallida).
- Tiempo de procesamiento en Dataproc.

Estos registros permiten evaluar el rendimiento del sistema y detectar patrones de comportamiento que puedan ser optimizados en futuras ejecuciones.

15.5.2. Registro de errores

El registro de errores almacena información detallada sobre fallos ocurridos durante la ejecución del ETL. Entre los errores más comunes que se contemplan se encuentran:

- Errores de formato en archivos de entrada.
- Fallos de conexión con servicios cloud.
- Inconsistencias en los datos que impiden su procesamiento.

Cada error es registrado con información contextual que facilita su análisis y corrección, contribuyendo a la estabilidad y confiabilidad del sistema.

15.5.3. Validación de Datos

La validación de datos se realiza como parte final del proceso ETL y tiene como objetivo asegurar que la información cargada en BigQuery cumple con los criterios de calidad definidos.

Las validaciones incluyen:

- Verificación de conteos de registros entre capas.
- Comprobación de integridad entre tablas de hechos y dimensiones.
- Validación de rangos y valores permitidos.
- Revisión de consistencia temporal y geográfica.

Este conjunto de validaciones garantiza que los datos analíticos reflejen de manera fiel la realidad epidemiológica, fortaleciendo la confiabilidad de los resultados obtenidos.

15.6. Diagrama Medallion Architecture

La arquitectura Medallion es un enfoque ampliamente utilizado en plataformas modernas de analítica de datos, ya que permite organizar el ciclo de vida de la información en capas claramente definidas según su nivel de procesamiento y calidad. En este proyecto, la arquitectura Medallion

se adopta como base para estructurar el Data Lake y el flujo ETL, garantizando trazabilidad, escalabilidad y control de calidad.

La solución implementada divide el almacenamiento de datos en tres capas principales: Bronce, Plata y Oro, cada una con un propósito específico dentro del proceso analítico. Este diseño facilita la identificación del estado de los datos y permite reprocesar información en caso de cambios en las reglas de negocio.

15.6.1. Situación Inicial de los Datos

En su estado inicial, los datos provenientes de EsSalud se encuentran en formatos heterogéneos y orientados a la operación diaria, no al análisis. Estos archivos contienen información clínica, demográfica y administrativa, presentando características como:

- Datos sin estandarización de formatos.
- Presencia de valores nulos y duplicados.
- Inconsistencias en la codificación de diagnósticos.
- Estructura no optimizada para consultas analíticas.

Esta situación inicial limita la capacidad de análisis y dificulta la generación de indicadores confiables, justificando la necesidad de un proceso ETL robusto y estructurado.

15.6.2. Bronce

La capa Bronce representa el nivel más bajo de la arquitectura Medallion y almacena los datos en su forma original, tal como son recibidos desde las fuentes de origen. En este proyecto, la capa Bronce se implementa mediante Cloud Storage, donde se almacenan los archivos CSV y XLS cargados automáticamente.

Diabetes	Hipertension	Obesidad	Ubigeo
Fecha_corte	Fecha_corte	Fecha_corte	Ubigeo
Departamento	Departamento	Departamento	Distrito
Provincia	Provincia	Provincia	Provincia
Distrito	Distrito	Distrito	Departamento
Ubigeo	Ubigeo	Ubigeo	Poblacion
Red	Red	Red	Superficie
Ipress	Ipress	Ipress	Y
ID_Paciente	ID_Paciente	ID_Paciente	X
Edad_Paciente	Edad_Paciente	Edad_Paciente	
Sexo_Paciente	Sexo_Paciente	Sexo_Paciente	
Edad_Medico	Edad_Medico	Edad_Medico	
ID_Medico	ID_Medico	ID_Medico	
Cod_Diagnostico	Cod_Diagnostico	Cod_Diagnostico	
Diagnostico	Diagnostico	Diagnostico	
Area_Hospitalaria	Area_Hospitalaria	Area_Hospitalaria	
Servicio_Hospitalario	Servicio_Hospitalario	Servicio_Hospitalario	
Actividad_Hospitalaria	Actividad_Hospitalaria	Actividad_Hospitalaria	
Fecha_Muestra	Fecha_Muestra	Fecha_Muestra	
Fecha_Resultado	Fecha_Resultado	Fecha_Resultado	
Procedimiento	Procedimiento	Procedimiento	
Resultado_1	Resultado_1	Resultado_1	
Unidades_1	Unidades_1	Unidades_1	
Fecha_Resultado	Fecha_Resultado	Fecha_Resultado	
Unidades_1	Unidades_1	Unidades_1	
Resultado_1	Resultado_1	Resultado_1	
Procedimiento	Procedimiento	Procedimiento	


Las principales características de la capa Bronce son:

- Conservación íntegra de los datos originales.
- Separación por fecha de carga y tipo de archivo.
- Trazabilidad completa del origen de la información.
- Posibilidad de reprocesamiento ante cambios en el ETL.

Esta capa cumple un rol fundamental como respaldo y punto de partida del proceso analítico, asegurando que ninguna información sea perdida o alterada prematuramente.

15.6.3. Plata

La capa Plata almacena los datos una vez que han sido sometidos a procesos de limpieza, estandarización y validación básica. En esta etapa, los datos adquieren una estructura más consistente y adecuada para análisis intermedios.




En el proyecto, la capa Plata se genera mediante procesos PySpark ejecutados en Dataproc, aplicando transformaciones como:

- Normalización de fechas y valores numéricos.
- Estandarización de diagnósticos clínicos.
- Eliminación de duplicados.
- Validación de campos obligatorios.

Los datos en esta capa se almacenan en formatos optimizados como Parquet, lo que mejora el rendimiento y reduce costos de almacenamiento. La capa Plata permite realizar análisis exploratorios y sirve como base para la generación de la capa analítica final.

15.6.4. Oro

La capa Oro representa el nivel más alto de la arquitectura Medallion y contiene los datos completamente refinados, listos para el análisis y la toma de decisiones. En esta etapa, la información se organiza bajo un modelo dimensional y se encuentra optimizada para consultas OLAP.



En esta solución, la capa Oro se integra directamente con BigQuery, donde se almacenan:

- Tablas de hechos relacionadas con diagnósticos y atenciones médicas.
- Tablas de dimensiones como tiempo, ubicación, enfermedad y paciente.
- Datos agregados y certificados para análisis epidemiológico.

La capa Oro es la fuente oficial de información para los dashboards desarrollados en Power BI. Su diseño garantiza consistencia, alto rendimiento y facilidad de uso para los analistas, cerrando el ciclo completo del proceso ETL.

16. CAPÍTULO V: DATA WAREHOUSE CLOUD

16.1. Modelo Dimensional

En el diseño del Data Warehouse para este proyecto, adoptamos un enfoque de modelado dimensional utilizando el diseño estrella (Star Schema). Este enfoque es ampliamente utilizado en el desarrollo de Data Warehouses debido a su simplicidad, flexibilidad y eficiencia en la consulta de grandes volúmenes de datos.

16.1.1. Diseño Estrella

El diseño estrella es un tipo de modelo dimensional que organiza los datos en tablas de hechos y dimensiones. Las tablas de hechos contienen las métricas de negocio, mientras que las tablas de dimensiones contienen las descripciones que permiten contextualizar estas métricas. Este modelo es adecuado para consultas rápidas y análisis de grandes volúmenes de datos.

Las tablas de hechos incluyen los eventos o transacciones de interés, como diagnósticos médicos o resultados de procedimientos. Las dimensiones proporcionan el contexto para estos hechos, como el tiempo, el paciente, la enfermedad, la ubicación geográfica, entre otros.

16.1.2. Diagrama de Hechos y Dimensiones

El diagrama de hechos y dimensiones ilustra la relación entre las tablas de hechos y las tablas de dimensiones en el modelo estrella. En este caso, el modelo dimensional para las enfermedades no transmisibles (ENT) incluye las siguientes tablas de hechos y dimensiones:

Tablas de Hechos:

- Hecho Diagnóstico (fact_diagnostico): Contiene información sobre los diagnósticos realizados a los pacientes, incluyendo el código de diagnóstico, el servicio hospitalario y la actividad hospitalaria.

- Hecho Resultado (fact_resultado): Registra los resultados de los procedimientos médicos realizados a los pacientes.

Tablas de Dimensiones:

- Dimensión Tiempo (dim_tiempo): Contiene información sobre las fechas de los diagnósticos y los resultados de los procedimientos.
- Dimensión Paciente (dim_paciente): Almacena información sobre los pacientes, como su código, edad y sexo.
- Dimensión Enfermedad (dim_enfermedad): Describe las enfermedades diagnosticadas a los pacientes, incluyendo el código de diagnóstico y su nombre.
- Dimensión Ubigeo (dim_ubigeo): Proporciona datos geográficos sobre la ubicación de los pacientes, como el departamento, provincia y distrito.
- Dimensión Procedimiento (dim_procedimiento): Incluye los procedimientos realizados, como las intervenciones médicas y las unidades asociadas.

16.2. Scripts SQL / DDL

Los scripts SQL (o DDL) son fundamentales para la creación de las tablas en el Data Warehouse de BigQuery. Estos scripts definen la estructura de las tablas y su relación con otras, permitiendo la carga y consulta eficiente de los datos.

16.2.1. Script de Creación de Tablas en BigQuery

Los scripts SQL (o DDL) son fundamentales para la creación de las tablas en el Data Warehouse de BigQuery. Estos scripts definen la estructura de las tablas y su relación con otras, permitiendo la carga y consulta eficiente de los datos.

16.2.1 Script de Creación de Tablas en BigQuery

A continuación se muestra el ejemplo de un script de creación de tabla para BigQuery, basado en el diseño estrella:

```
-- Crear tabla de dimensión Tiempo
CREATE OR REPLACE TABLE `proyecto_id.oro.dim_tiempo` AS
SELECT
  GENERATE_UUID() AS SK_Tiempo,
  fecha,
  EXTRACT(YEAR FROM fecha) AS año,
  EXTRACT(MONTH FROM fecha) AS mes,
  EXTRACT(DAY FROM fecha) AS día,
  EXTRACT(WEEK FROM fecha) AS semana,
  EXTRACT(QUARTER FROM fecha) AS trimestre,
  LAST_DAY(fecha, MONTH) AS fin_de_mes
FROM `proyecto_id.datalake.bronce_diagnostico`
```

Este script crea la tabla dim_tiempo utilizando datos de la capa Bronce y agrega columnas calculadas para los diferentes desgloses temporales (año, mes, día, semana, trimestre).

16.2.2. Ejecución de Script de Creación de Tablas

La ejecución de los scripts de creación de tablas se realiza directamente en BigQuery a través de su interfaz de línea de comandos o mediante la integración con herramientas como Cloud SDK o Google Cloud Console. Estos scripts son ejecutados en secuencia después de haber procesado los datos en las capas Bronce y Plata, para generar las tablas de Oro, que son las que alimentarán las consultas analíticas finales.

El proceso de ejecución también está automatizado mediante Cloud Functions o Cloud Run para asegurar que cada tabla se cree en el momento adecuado del flujo ETL, alineado con los eventos de carga de datos en la plataforma.

16.3. Consultas OLAP

Una vez implementado el modelo dimensional en BigQuery, se habilita la ejecución de consultas OLAP (Online Analytical Processing) orientadas al análisis epidemiológico de enfermedades no transmisibles (ENT). Estas consultas permiten explorar los datos desde múltiples perspectivas (tiempo, ubicación, enfermedad, grupo etario), aprovechando el esquema estrella diseñado.

El uso de BigQuery como motor analítico serverless permite ejecutar consultas complejas sobre grandes volúmenes de datos con tiempos de respuesta reducidos, sin necesidad de administrar infraestructura.

Tipos de consultas OLAP implementadas. Las consultas desarrolladas se agrupan en las siguientes categorías:

- **Análisis temporal**

Permite evaluar la evolución de los diagnósticos de ENT por año, mes o trimestre, identificando tendencias y estacionalidades.

Ejemplos:

- Número de diagnósticos de diabetes por mes.
- Comparación interanual de casos de hipertensión.

- **Análisis geográfico**

Utiliza la dimensión UBIGEO para identificar la distribución espacial de ENT.

Ejemplos:

- Diagnósticos por departamento y provincia.
- Identificación de distritos con mayor concentración de casos.

- **Análisis demográfico**

Permite segmentar los casos según características del paciente.

Ejemplos:

- Casos por grupo etario.
- Distribución de ENT por sexo.

- **Análisis por tipo de enfermedad**

Facilita la comparación entre diabetes, hipertensión y obesidad.

Ejemplos:

- Participación porcentual de cada ENT.
- Evolución de cada enfermedad en el tiempo.

Ejemplo de consulta OLAP en BigQuery

```
SELECT
```

```
  t.anio,
```

```
  e.grupo_enfermedad,
```

```
  COUNT(*) AS total_diagnosticos
```

```
FROM fact_diagnostico f
```

```
JOIN dim_tiempo t ON f.sk_tiempo = t.sk_tiempo
```

```
JOIN dim_enfermedad e ON f.sk_enfermedad = e.sk_enfermedad
```

```
GROUP BY t.anio, e.grupo_enfermedad
```

```
ORDER BY t.anio;
```

Este tipo de consulta es consumido directamente por Power BI, donde se transforma en visualizaciones interactivas como gráficos de líneas y barras, permitiendo una interpretación intuitiva de los resultados.

16.4. Validación de Integración con ETL

La validación de la integración entre el proceso ETL y el Data Warehouse es una etapa crítica para garantizar que los datos transformados en Dataproc (Spark) se cargan correctamente en BigQuery y mantienen coherencia estructural y semántica.

Esta validación se realiza considerando dos dimensiones principales:

- evidencia de carga correcta
- consistencia de los datos

16.4.1. Evidencia de Carga Correcta

La evidencia de carga correcta se verifica mediante:

- Existencia de tablas en BigQuery

Se comprueba que todas las tablas definidas en el modelo dimensional (dimensiones y hechos) se hayan creado correctamente en los datasets correspondientes de la capa Oro.

- Conteo de registros

Se comparan los conteos de registros entre:

- Datos procesados en la capa Plata (Spark).
- Tablas finales en BigQuery (Oro).

Esto permite asegurar que no se han perdido registros durante la carga.

- Logs del proceso ETL

Los logs generados por Dataproc y orquestados vía Cloud Run confirman:

- Ejecución exitosa de los jobs Spark.
- Finalización correcta de la escritura en BigQuery.
- Ausencia de errores críticos durante la carga.

- Disponibilidad inmediata para BI

Las tablas cargadas son visibles y accesibles desde Power BI mediante el conector nativo de BigQuery, validando la correcta publicación de los datos.

16.4.2. Consistencia de Datos

La consistencia de los datos se valida a través de controles cruzados entre dimensiones y hechos:

- Integridad referencial lógica

Se verifica que todas las claves foráneas presentes en las tablas de hechos tengan correspondencia en sus respectivas dimensiones (tiempo, paciente, enfermedad, ubigeo, procedimiento).

Ejemplo: Cada sk_enfermedad en fact_diagnostico existe en dim_enfermedad.

- Coherencia semántica

Se valida que los valores agregados coincidan con el significado epidemiológico esperado:

- No existen diagnósticos con fechas futuras.
- Los grupos etarios corresponden a rangos válidos de edad.
- Los códigos CIE se agrupan correctamente en las ENT definidas.

- Comparación antes y después del ETL

Se contrastan métricas básicas (totales, promedios, mínimos y máximos) entre los datos originales (Bronce) y los datos finales (Oro), confirmando que las transformaciones aplicadas en Spark no distorsionan la información.

17. CAPÍTULO VI: DASHBOARD ANALÍTICO

17.1. Conexión con BigQuery

Este capítulo detalla el proceso de visualización de datos, desde la conexión técnica segura con la nube hasta la construcción de los indicadores visuales para la toma de decisiones.

17.1.1. Descripción del proceso de conexión

Para iniciar el proceso de visualización, se estableció una conexión directa entre Power BI Desktop y el Data Warehouse en Google BigQuery. El objetivo fue consumir la tabla `oro.kpi_reporte_powerbi`, la cual fue generada previamente por el proceso ETL y contiene la información consolidada lista para análisis.


El procedimiento realizado fue el siguiente:


- Selección de Fuente: En Power BI, se utilizó la opción "Obtener datos" y se seleccionó el conector nativo de Google BigQuery.
- Modo de Conectividad: Se optó por el modo Importar (Import Mode). Esta configuración carga los datos en la memoria caché de Power BI, garantizando un alto rendimiento y velocidad de respuesta en la interacción con los gráficos, a diferencia del modo DirectQuery que dependería de la latencia de red.

17.1.2. Evidencia de conexión


El proceso de conexión fue exitoso, permitiendo la previsualización y carga de la tabla de KPIs. Se validó la integridad de los campos principales: temporales (Año, Mes), geográficos (Departamento, Distrito) y clínicos (Enfermedad, Grupo Etario).

- Se elige la conexión con BigQuery:






- Se ingresan las credenciales que se detallan en la siguiente sección:



- Prueba de conexión exitosa:




17.1.3. Configuración de credenciales

Para garantizar la seguridad y el acceso restringido a los datos sensibles de salud, no se utilizaron credenciales de usuario personal, sino una Service Account (Cuenta de Servicio) de Google Cloud.

- Cuenta de Servicio: service-account@grupo2-essalud.iam.gserviceaccount.com
- Método de Autenticación: Se generó una llave de seguridad tipo JSON desde la consola de Google Cloud IAM.

Implementación: El contenido del archivo JSON (Clave privada) se copió y pegó directamente en el campo de autenticación de Power BI, permitiendo el "handshake" seguro entre la herramienta de Microsoft y la nube de Google.



17.2. Dashboard Analítico


El diseño del dashboard sigue un enfoque ejecutivo y epidemiológico, estructurado en cinco pestañas para facilitar la navegación desde lo general a lo específico. Se definieron medidas DAX base

como $\text{Atenciones} = \text{SUM}(\text{total_atenciones})$ y $\text{Pacientes} = \text{SUM}(\text{pacientes_unicos})$ para estandarizar los cálculos.

17.2.1. Pestaña 1

17.2.1.1. Reporte

Esta página funciona como un Executive Summary. Su objetivo es mostrar el estado de salud general de la población analizada y comparar el peso relativo de las tres grandes patologías (Diabetes, Hipertensión y Obesidad). Permite identificar rápidamente tendencias temporales y la distribución demográfica básica de los pacientes.



17.2.1.2. KPI's principales visualizados

En esta sección se visualizan los indicadores macro del negocio:

- Total de Atenciones: (KPI N° 1) Mide la carga operativa total del sistema de salud en el periodo.
- Pacientes Únicos Atendidos: (KPI N° 2) Cantidad de personas distintas atendidas.

17.2.2. Pestaña 2

17.2.2.1. Reporte

Diseñada para profundizar el análisis geográfico en la capital, donde reside la mayor densidad poblacional. Se aplica un filtro de página fijo (Departamento = LIMA) para permitir un desglose a nivel de Provincia y Distrito. Es fundamental para la gestión de recursos hospitalarios en la zona metropolitana.



17.2.2.2. KPI's principales visualizados

Se centra en la distribución espacial de la demanda:

- Intensidad de Casos en Lima: (KPI N° 9) Porcentaje de atenciones concentradas en la capital respecto al total nacional.
- Mapa de Calor Distrital: Visualización de Pacientes Únicos por distrito para identificar "zonas calientes".
- Ranking de Servicios: Volumen de atenciones por especialidad médica dentro de Lima.

17.2.3. Pestaña 3

17.2.3.1. Reporte

Primera página temática enfocada exclusivamente en el grupo de enfermedad Diabetes. Permite a los especialistas analizar qué subtipos de diabetes son los más frecuentes y cómo afecta esta patología a los diferentes grupos de edad.



17.2.3.2. KPI's principales visualizados


- Población con Diabetes: (KPI N° 3) Conteo distinto de pacientes diagnosticados con este grupo de enfermedad.

- Tasa de Prevalencia de Diabetes: (KPI N° 7) Porcentaje que representan los casos de diabetes respecto al universo total de atenciones.
- Desglose por Subtipo: Ranking de diagnósticos específicos (ej. Diabetes Mellitus Tipo 2 vs Tipo 1).

17.2.4. Pestaña 4

17.2.4.1. Reporte

Página temática dedicada al análisis de la Hipertensión Arterial. Dado que esta enfermedad suele correlacionarse con la edad avanzada, el reporte pone énfasis en el análisis demográfico y los grupos de riesgo.



17.2.4.2. KPI's principales visualizados

- Población con Hipertensión: (KPI N° 4) Pacientes únicos diagnosticados con hipertensión.
- Atenciones en Adultos Mayores: (KPI N° 8) Volumen de atenciones en el segmento +60 años, grupo crítico para esta patología.
- Pirámide Poblacional de Hipertensos: Distribución de pacientes por sexo y grupo etario.

17.2.5. Pestaña 4

17.2.5.1. Reporte

Última página temática enfocada en Obesidad. Este reporte busca identificar patrones en grupos etarios más jóvenes (menores y adultos) y su distribución geográfica, dado que suele ser un factor de riesgo para las otras dos patologías analizadas.



17.2.5.2. KPI's principales visualizados

- Población con Obesidad: (KPI N° 5) Pacientes únicos con diagnóstico de obesidad.
- Tendencia Mensual: Evolución de los casos de obesidad a lo largo del año para detectar estacionalidad o efectividad de campañas de salud.
- Distribución Geográfica: Mapa de calor nacional identificando las regiones con mayores tasas de obesidad.

18. CAPÍTULO VII: DOCUMENTACIÓN Y EVIDENCIA DE DESPLIEGUE

Este capítulo detalla la arquitectura técnica implementada en Google Cloud Platform (GCP), describiendo el flujo de trabajo, la configuración de los servicios involucrados y la estimación económica del proyecto.

18.1. Flujo de Trabajo en GCP

El proyecto utiliza una arquitectura "Event-Driven" (orientada a eventos) y "Serverless" (sin servidor), lo que significa que los recursos solo se activan cuando hay datos nuevos que procesar, optimizando costos y mantenimiento.

18.1.1. Configuración por servicio

A continuación, se detalla la configuración técnica de cada componente desplegado:

- Cloud Storage (Capa de Almacenamiento):
 - Bucket: grupo2-essalud-datalake
 - Estructura: Carpetas /bronce (entrada), /plata, /oro y /scripts.
 - Función: Repositorio central de datos y disparador de eventos.
- Cloud Run (Orquestador Ligero):
 - Nombre del servicio: validar-archivo
 - Trigger: Eventarc conectado a google.cloud.storage.object.v1.finalized (evento de archivo creado).
 - Lógica: Script en Python (main.py) que valida si el archivo subido es uno de los permitidos (Diabetes, Hipertensión, Obesidad) para evitar bucles infinitos.
 - Acción: Utiliza la librería google-cloud-dataproc para instanciar un lote de procesamiento.
- Dataproc Serverless (Procesamiento):

- Tipo: Batches (Lotes) Spark.
- Versión del Runtime: 2.2 (Spark 3.5).
- Estrategia "Low Cost": Se configuró el job para evitar el auto-escalado masivo y controlar costos.
 - spark.driver.cores: 4 vCPU
 - spark.executor.cores: 4 vCPU
 - spark.executor.instances: 2 (Mínimo requerido por GCP).
 - spark.dynamicAllocation.mode: OFF.
- BigQuery (Data Warehouse):
 - Dataset: grupo2-essalud
 - Tablas: Esquema en estrella (Hechos y Dimensiones) y tabla plana para Power BI.

18.1.2. Ejecución

El ciclo de vida de una ejecución del ETL es el siguiente:

1. Ingesta: El usuario sube los archivos CSV (Diabetes.csv, etc.) a la carpeta bronce/ en Cloud Storage.
2. Detección: Cloud Run detecta el evento. Filtra el archivo y, si es válido, solicita la creación de un Batch en Dataproc.
3. Procesamiento: Dataproc levanta un clúster efímero, descarga el script etl_script.py y ejecuta las transformaciones (limpieza, joins, cálculo de dimensiones).
4. Carga: Spark escribe los resultados procesados directamente en BigQuery y genera copias de respaldo en CSV en las carpetas plata/ y oro/.
5. Reporte: Finalmente, se actualiza la tabla oro.kpi_reporte_powerbi mediante una consulta SQL embebida en el script.

18.2. Flujo de Datos General

El flujo de datos sigue la arquitectura Medallion para garantizar la calidad de la información:

1. Capa Bronce (Raw): Ingesta directa de los CSVs originales (Diabetes, Hipertensión, Obesidad) sin modificaciones.
2. Capa Plata (Clean):
 - Estandarización de nombres de columnas.
 - Eliminación de duplicados.
 - Normalización de fechas (formato yyyyMMdd).
 - Separación en entidades: Paciente, Médico, Ubigeo, Enfermedad.
3. Capa Oro (Business):
 - Creación del Modelo Dimensional (Esquema Estrella).
 - Generación de Fact_Diagnostico y Dim_Tiempo.
 - Cálculo de la tabla agregada de KPIs para consumo final en Power BI.

18.3. Bitácora de Versionamiento

18.4. Costos de Despliegue

18.4.1. Estimación de costos en GCP

Dado que la arquitectura es Serverless, los costos son por uso. La siguiente tabla estima el costo por cada ejecución completa del ETL (aprox. 5 a 10 minutos de duración).

Servicio	Métrica de Cobro	Consumo Estimado por Ejecución	Costo Unitario Aprox.	Costo Total Est. (USD)
Cloud Storage	Almacenamiento y Operaciones	< 1 GB / Clase A Ops	\$0.020 / GB mes	< \$0.01
Cloud Run	CPU/Memoria por segundo	200ms de invocación	\$0.0000240 / vCPU-seg	< \$0.01
Dataproc Serverless	DCU (Data Compute Unit)	12 vCPUs x 10 min	~\$0.06 / DCU-hora	~\$0.15
BigQuery	Almacenamiento y Queries	< 100 MB procesados	\$5.00 / TB procesado	< \$0.01
Total por Ejecución				~ \$0.18 USD

19. CAPÍTULO VIII: LIMITACIONES, PROPUESTAS Y CONCLUSIONES

19.1. Limitaciones Encontradas

Durante la ejecución del proyecto se identificaron las siguientes restricciones técnicas y operativas:

- Dependencia de Archivos Simultáneos: El script ETL actual está diseñado de forma monolítica; requiere que los tres archivos fuente (Diabetes.csv, Hipertension.csv, Obesidad.csv) existan en el bucket al momento de la ejecución. Si falta uno, el proceso falla.
- Latencia en Power BI: Al utilizar el modo "Importar" para optimizar costos, los datos en el dashboard no son estrictamente "en tiempo real", dependiendo de la actualización programada o manual del dataset.
- Restricciones de Cuota: El uso de Dataproc Serverless impone un mínimo de 12 vCPUs, lo que impide reducir el hardware por debajo de ese umbral para cargas de trabajo muy pequeñas.

19.2. Propuestas de Mejora

Para futuras iteraciones del proyecto, se sugieren las siguientes optimizaciones:

- Orquestación con Cloud Composer (Airflow): Implementar un DAG de Airflow permitiría manejar dependencias complejas (ej. esperar a que lleguen los 3 archivos antes de iniciar Dataproc) y reintentos automáticos ante fallos.
- Carga Incremental: Modificar el script para usar MERGE en BigQuery en lugar de Overwrite. Esto permitiría procesar solo los datos nuevos del día, reduciendo el tiempo de procesamiento y costos a medida que el histórico crece.
- Validación de Calidad de Datos (Data Quality): Integrar librerías como Great Expectations dentro del ETL para validar que no existan nulos en campos críticos (DNI, Fechas) antes de escribir en la Capa Oro.

19.3. Conclusiones

- Se logró implementar un flujo ETL completamente automatizado sin necesidad de aprovisionar o mantener servidores fijos. Esto reduce drásticamente la carga administrativa y alinea los costos directamente con el uso real del sistema.

- Se demostró la capacidad de integración nativa entre los servicios de Google Cloud (Storage, Run, Dataproc, BigQuery) y herramientas externas de visualización (Power BI), estableciendo un canal seguro mediante Cuentas de Servicio.
- La transformación de datos crudos en un modelo dimensional (Esquema Estrella) ha permitido convertir registros operativos aislados en información estratégica, facilitando la identificación de patrones epidemiológicos en Diabetes, Hipertensión y Obesidad en la población asegurada.

20. BIBLIOGRAFÍA

- G, R., K, S., K, P., Mp, P., & M, U. (2025). Efficient Diabetes Detection And Diet Recommendation System Using Ensemble Framework On Big Data Clouds. Global Journal of Engineering Innovations and Interdisciplinary Research. <https://doi.org/10.33425/3066-1226.1108>.
- Solige, S. (2025). Scalable Data Transformations and Real-Time Processing in Healthcare Cloud Platforms. International Journal of Scientific Research in Computer Science, Engineering and Information Technology. <https://doi.org/10.32628/cseit25112545>.
- Chillara, S. (2025). Leveraging cloud-based BI architecture for scalable healthcare analytics: A technical framework for transformation. World Journal of Advanced Engineering Technology and Sciences. <https://doi.org/10.30574/wjaets.2025.15.1.0489>.
- Kong, X., Peng, R., Dai, H., Li, Y., Lu, Y., Sun, X., Zheng, B., Wang, Y., Zhao, Z., Liang, S., & Xu, M. (2022). Disease-specific data processing: An intelligent digital platform for diabetes based on model prediction and data analysis utilizing big data technology. Frontiers in Public Health, 10. <https://doi.org/10.3389/fpubh.2022.1053269>.
- Tawalbeh, L., Mehmood, R., Benkhelifa, E., & Song, H. (2016). Mobile Cloud Computing Model and Big Data Analysis for Healthcare Applications. IEEE Access, 4, 6171-6180. <https://doi.org/10.1109/access.2016.2613278>.
- Talakola, S. (2022). Analytics and reporting with Google Cloud platform and Microsoft Power BI. International Journal of Artificial Intelligence, Data Science, and Machine Learning. <https://doi.org/10.63282/3050-9262.ijaidsm-l-v3i2p106>.