

UNIVERSIDAD NACIONAL DE INGENIERÍA
FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS



SI807 U SISTEMAS DE INTELIGENCIA DE NEGOCIOS

“ Construcción de Pipeline ETL en Google Cloud Platform (GCP)”

PC3

Empresa: Cencosud

GRUPO N° 9:

LARICO CRUZ, DIEGO CÉSAR

CABANA CAZANI, GABRIEL ALESSANDRO

ÍNDICE

JUSTIFICACIÓN DE LA ELECCIÓN DE LA NUBE	3
PASOS PARA CREACIÓN DEL ETL	8
Paso 1: Ingesta de Datos (Cloud Storage).....	8
Paso 2: Capa Raw (BigQuery)	8
Paso 3: Transformación con Spark (Dataproc)	8
Paso 4: Carga a Tablas Curated (BigQuery)	9
Paso 5: Cubo OLAP (BigQuery SQL)	10
Paso 6: Dashboard (Looker Studio)	10
Paso 7: Monitoreo y Limpieza (¡CRÍTICO!)	11
EVALUACIÓN DE COSTOS.....	11

JUSTIFICACIÓN DE LA ELECCIÓN DE LA NUBE

Introducción y Decisión

Para la implementación de la arquitectura de datos, flujo ETL y Business Intelligence del presente proyecto, se ha seleccionado **Google Cloud Platform (GCP)**. Esta decisión es el resultado de un análisis comparativo técnico y comercial frente a los otros dos líderes del cuadrante de Gartner: **Amazon Web Services (AWS)** y **Microsoft Azure**.

La elección prioriza la arquitectura "**Serverless**" (sin servidor), la integración nativa de herramientas de Big Data y la eficiencia en costos para un proyecto piloto escalable.

Característica / Criterio	Google Cloud (GCP) (Seleccionada)	Amazon Web Services (AWS)	Microsoft Azure
1. Data Warehouse & Escalabilidad	BigQuery : Arquitectura 100% Serverless. Escala de gigabytes a petabytes automáticamente sin gestionar nodos ni clústeres. Rendimiento	Redshift: Tradicionalmente basado en clústeres provisionados. Aunque ofrece "Serverless", la configuración de red (VPC) y mantenimiento es más compleja.	Synapse Analytics: Potente integración empresarial, pero requiere aprovisionamiento de "Data Warehouse Units" (DWU) y su curva de configuración es alta.

Característica / Criterio	Google Cloud (GCP) (Seleccionada)	Amazon Web Services (AWS)	Microsoft Azure
	superior en consultas ad-hoc.		
2. Ecosistema de BI (Visualización)	Looker Studio: Solución nativa web, gratuita y con conexión directa a BigQuery. No requiere instalación de software ni drivers ODBC.	QuickSight : Modelo de pago por sesión/autor. Menos intuitivo para usuarios de negocio y con menos opciones de personalización gratuita.	Power BI: Líder del mercado, pero requiere licencias "Pro" para compartir reportes y configuración de Gateways para conectar con ciertas fuentes de datos.
3. Procesamiento Big Data (ETL)	Dataproc & Dataflow: Dataproc levanta clústeres de Spark en ~90 segundos (vs 10-	EMR (Elastic MapReduce): El estándar de la industria, muy robusto, pero	HDInsight / Databricks: Azure Databricks es excelente pero costoso; HDInsight

Característica / Criterio	Google Cloud (GCP) (Seleccionada)	Amazon Web Services (AWS)	Microsoft Azure
	15 min en otros), ideal para procesos efímeros y ahorro de costos.	complejo de configurar para cargas de trabajo simples o esporádicas.	es más complejo de administrar.
4. Almacenamiento (Data Lake)	Cloud Storage (GCS): Sistema de archivos unificado y simple. Maneja automáticamente las clases de almacenamiento y la redundancia regional.	S3 (Simple Storage Service): El más maduro y granular, pero la gestión de políticas de acceso (IAM) y buckets puede ser abrumadora al inicio.	Data Lake Storage Gen2: Requiere configuración de jerarquías de archivos y permisos POSIX, añadiendo complejidad a la ingesta simple.
5. Modelo de Precios (Pricing)	Agresivo y Transparente:	Capa Gratuita	Corporativo: \$200 USD de

Característica / Criterio	Google Cloud (GCP) (Seleccionada)	Amazon Web Services (AWS)	Microsoft Azure
	Ofrece \$300 USD de créditos iniciales y una capa gratuita generosa (ej. 1TB de consultas BigQuery/mes gratis). Cobro por segundo en muchos servicios.	Limitada: 12 meses de servicios limitados. Estructura de costos compleja y difícil de predecir sin calculadoras avanzadas.	crédito inicial. Modelo de licencias ventajoso solo si ya se posee un contrato Enterprise Agreement (EA) con Microsoft.
6. Seguridad y Gestión	IAM Simplificado: Gestión de identidades centralizada y orientada a proyectos.	IAM Granular: Extremadamente potente pero complejo; es fácil cometer errores de seguridad (ej.	Active Directory: Excelente si la empresa ya usa AD, pero añade una capa de complejidad innecesaria para

Característica / Criterio	Google Cloud (GCP) (Seleccionada)	Amazon Web Services (AWS)	Microsoft Azure
	Encriptación en reposo y en tránsito activada por defecto sin configuración extra.	buckets públicos) si no se es experto.	proyectos nativos de nube aislados.

PASOS PARA CREACIÓN DEL ETL

Paso 1: Ingesta de Datos (Cloud Storage)

En lugar de subir archivos a HDFS mediante Ambari, usaremos "Buckets" (cubetas) en la nube.

1. Crear el Bucket:

- Ve a la consola de GCP → Menú → **Cloud Storage** → **Buckets**.
- Haz clic en **CREAR**.
- Nombre único: etl-ventas-proyecto-[tu-nombre].
- Configuración: Déjalo en "Regional" (us-central1) y "Standard". Crear.

2. Crear Estructura de Carpetas:

- Dentro del bucket, crea 3 carpetas: raw, curated, analytics.
- Dentro de raw, crea las subcarpetas igual que antes: dim_cliente, fact_hecho_venta, etc.

3. Subir los CSVs:

- Entra a cada carpeta (ej. raw/dim_cliente/) y sube el archivo CSV correspondiente desde tu PC.

Paso 2: Capa Raw (BigQuery)

En lugar de CREATE EXTERNAL TABLE en Hive, crearemos tablas en BigQuery que "apunten" a tus CSVs en el Storage.

1. Crear el Dataset (Base de Datos):

- Ve al Menú → **BigQuery**.
- Al lado de tu proyecto, haz clic en los 3 puntos → **Crear conjunto de datos** (Create dataset).
- ID: dwh_ventas. Ubicación: us-central1.

2. Crear Tablas Externas:

- Selecciona el dataset dwh_ventas → **Crear Tabla**.
- **Crear tabla desde:** Google Cloud Storage.
- **Ruta GCS:** etl-ventas-proyecto-[tu-nombre]/raw/dim_cliente/*.csv
- **Formato:** CSV.
- **Nombre de tabla:** dim_cliente_raw.
- **Tipo de tabla:** Externa (External table).
- **Esquema:** Marca "Detectar automáticamente" (Auto detect). *¡Mucho más fácil que Hive!*
- **Opciones avanzadas:** "Filas de encabezado que saltar": 1.
- Haz clic en **Crear Tabla**.
- *(Repite para las 6 tablas).*

Paso 3: Transformación con Spark (Dataproc)

Aquí reemplazamos tu VM de Hortonworks con un clúster real y efímero.

1. **Habilitar API:** Busca "Dataproc API" y habilítala.
2. **Crear Clúster:**
 - Menú → **Dataproc** → **Clústeres** → **Crear Clúster**.
 - Nombre: cluster-etl-spark. Región: us-central1.
 - **Tipo:** "Un solo nodo" (Single Node) - *Para ahorrar costos en pruebas.*
 - **Componentes:** Marca "Jupyter Notebook" en la sección de Puerta de enlace de componentes.
 - **Crear.** (Tardará unos 90 segundos).
3. **Abrir JupyterLab:**
 - Una vez creado, haz clic en el nombre del clúster \$to\$ Pestaña **Interfaces web** → **JupyterLab**.
4. **El Código PySpark (Adaptado a GCP):**
 - Crea un nuevo Notebook (PySpark).
 - El código es casi idéntico al anterior, pero leyendo/escribiendo en GCS.

Python

```
from pyspark.sql.functions import col, to_date, when, lit, upper, trim
```

```
# Rutas GCS (¡CAMBIA ESTO POR TU BUCKET!)
```

```
BUCKET = "gs://etl-ventas-proyecto-[tu-nombre]"
```

```
# 1. Leer desde BigQuery o CSV directo
```

```
# (Leemos CSV directo para simplificar configuración)
```

```
df_cliente = spark.read.csv(f'{BUCKET}/raw/dim_cliente/*.csv', header=True,
inferSchema=True)
```

```
# 2. Transformaciones (¡Las mismas que hiciste antes!)
```

```
df_cliente_curated = df_cliente.withColumn(
    "fecha_alta_cliente_dt", to_date(col("fecha_alta_cliente"), "yyyy-MM-dd")
).na.fill("SIN TARJETA", ["numero_tarjeta_bonus"])
```

```
# ... (Repite la lógica para todas las tablas) ...
```

```
# 3. Escribir a GCS en formato PARQUET (Capa Curated)
```

```
df_cliente_curated.write.mode("overwrite").parquet(f'{BUCKET}/curated/dim_cliente/')
print("Dim Cliente procesada y guardada en GCS Curated")
```

Paso 4: Carga a Tablas Curated (BigQuery)

Ahora hacemos disponibles esos archivos Parquet limpios en BigQuery.

1. Vuelve a **BigQuery**.
2. En tu dataset dwh_ventas, crea nuevas tablas.
3. **Crear tabla desde:** Google Cloud Storage.
4. **Ruta:** etl-ventas-proyecto-[tu-nombre]/curated/dim_cliente/*.parquet
5. **Formato:** Parquet.

6. **Nombre:** dim_cliente_curated.
7. **Tipo de tabla:** Nativa (Native table) - *Esto cargará los datos para que sea súper rápido.*
8. Crear Tabla.

(Repite para las 6 tablas).

Paso 5: Cubo OLAP (BigQuery SQL)

En lugar de esperar 5 minutos como en Hive, BigQuery hará esto en segundos.

1. En BigQuery, abre una pestaña de consulta (Query).
2. Ejecuta tu SQL de agregación (adaptando los nombres de tablas):

SQL

```
CREATE OR REPLACE TABLE `dwh_ventas.resumen_ventas_analytics` AS
SELECT
  p.anio, p.nombre_mes,
  t.ciudad, t.nombre_tienda,
  pr.categoria, pr.marca,
  SUM(f.monto_venta_neta) AS total_ventas_netas,
  COUNT(DISTINCT f.cod_ticket) AS total_tickets
FROM
  `dwh_ventas.fact_hecho_venta_curated` f
JOIN
  `dwh_ventas.dim_periodo_curated` p ON f.sk_periodo = p.sk_periodo
JOIN
  `dwh_ventas.dim_tienda_canal_curated` t ON f.sk_tienda = t.sk_tienda
JOIN
  `dwh_ventas.dim_producto_curated` pr ON f.sk_producto = pr.sk_producto
GROUP BY
  1, 2, 3, 4, 5, 6;
```

Paso 6: Dashboard (Looker Studio)

Aquí es donde verás la magia de la integración nativa.

1. Ve a **Looker Studio** (lookerstudio.google.com).
2. **Crear** → **Informe**.
3. Te pedirá conectar datos: Selecciona **BigQuery**.
4. Elige tu PROYECTO → Dataset dwh_ventas → Tabla resumen_ventas_analytics.
5. Haz clic en **Añadir**.
6. ¡Listo! Arrastra y suelta para crear tus KPIs (Ticket Promedio, Ventas por Categoría) tal como te enseñé en las respuestas anteriores.

Paso 7: Monitoreo y Limpieza (¡CRÍTICO!)

1. **Monitoreo:** Ve a la consola de GCP \$to\$ **Operations** → **Logging**. Ahí verás los logs de Dataproc y BigQuery si algo falla.
2. **Limpieza (Ahorro de dinero):**
 - **Dataproc:** Apenas termines de ejecutar tu código Spark, **BORRA EL CLÚSTER**. Es lo que más cobra (aunque es barato, si lo dejas prendido días te consumirá el crédito).
 - **Storage y BigQuery:** Son baratísimos, puedes dejarlos.

EVALUACIÓN DE COSTOS

SERVICIO	ESPECIFICACIONES	PRIMER MES	PROYECCION 6 MESES
GCS STORAGE	Total amount of storage - 15 TiB Location type - Region Location - Iowa (us-central1) Storage class - Standard Storage Source region - North America Destination region - North America	\$307,10	\$1.842,60
BIG QUERY	Location type - Region Location - Iowa (us-central1) Edition - Enterprise Maximum slots - Small (100 slots) Baseline slots - 100 Commitment - 1 Year Average utilization of autoscale slots - 50	\$3.974,81	\$23.848,86
DATAPROC SERVERLESS	Number of vCPUs - 4 Memory per vCPU (GiB) - 16 GiB Region - Iowa (us-central1) Usage time - 30 Hours Interactive - false Add GPUs - false Current cluster utilization % - 50	\$416,10	\$2.496,60
		TOTAL	\$28.188,06

