

Documentación de Arquitectura Pipeline ETL en GCP (Event-Driven)

1. Capa de Origen e Ingesta (Event-Driven Trigger)

Esta fase inicia el flujo automáticamente apenas un archivo es cargado, eliminando tiempos muertos de espera.

- **Archivos .csv (Origen de Datos):**
 - Representan la data cruda. Son subidos manualmente o por sistemas externos al bucket.
- **Cloud Storage (Landing Zone):**
 - **Función:** Almacenamiento de objetos.
 - **Acción:** Recibe el archivo .csv. Al completarse la carga (Upload), genera automáticamente una **Notificación** a Pub/Sub.
- **Pub/Sub & Cloud Functions (El Disparador):**
 - **Pub/Sub:** Cola de mensajería que recibe la notificación de que "llegó un archivo".
 - **Cloud Functions:**
 - **Función:** Microservicio ligero de "escucha".
 - **Acción (Push Event):** Se activa al recibir el mensaje de Pub/Sub y ejecuta una llamada a la API de Cloud Composer para **despertar al DAG** (flujo de trabajo) específico.

2. Capa de Orquestación (The Brain)

Aquí reside la inteligencia del flujo. A diferencia del ejemplo anterior, usas un orquestador dedicado.

- **Cloud Composer (Airflow):**
 - **Función:** Gestión de flujo de trabajo y dependencias.
 - **Acción (Trigger DAG):**
 1. Recibe la orden de la Cloud Function.
 2. **Inicia JOB:** Coordina la creación del clúster de Dataproc.
 3. **Gestiona Tablas:** Verifica o prepara las tablas en BigQuery.
 4. **Secuencialidad:** Asegura que el Stored Procedure no corra hasta que el trabajo de Spark haya terminado exitosamente.

3. Capa de Almacenamiento (Data Warehouse - BigQuery)

Estrategia de capas "Medallion" (Bronce, Plata, Oro) gestionada dentro de BigQuery.

- **BigQuery Raw (Bronce):**
 - **Función:** Repositorio de datos crudos.
 - **Acción:** El DAG puede cargar aquí el CSV tal cual llega, o Dataproc puede leer directamente desde Cloud Storage. Es la copia fiel del archivo.
- **BigQuery Curated (Plata):**
 - **Función:** Datos limpios y estructurados.
 - **Acción:** Recibe los datos transformados por **Spark**. Aquí los tipos de datos (fechas, números) ya son correctos y se han eliminado duplicados técnicos.
- **BigQuery Analytics (Oro/Consumo):**
 - **Función:** Datos agregados para negocio.
 - **Acción:** Resultado del **Stored Procedure**. Contiene tablas listas para conectar con Looker, con la lógica de negocio aplicada (KPIs).

4. Capa de Procesamiento (Híbrido: Spark + SQL)

Combinas la potencia de Spark para Big Data con la eficiencia de SQL para transformaciones finales.

- **Dataproc (PySpark Job):**
 - **Función:** Procesamiento pesado (ETL).
 - **Acción (Spark Read / Overwrite/Append):**
 1. Cloud Composer levanta el trabajo.
 2. Lee los datos crudos.
 3. Aplica transformaciones complejas en Python/Spark.
 4. Escribe el resultado limpio en la capa **Curated**.
- **Stored Procedure (SQL):**
 - **Función:** Transformación ELT (In-Database).
 - **Acción (SQL Merge):**
 1. Toma los datos de **Curated** como Input.

2. Ejecuta un MERGE (Actualizar si existe, Insertar si es nuevo) hacia la capa **Analytics**.
3. Ideal para lógica de negocio relacional y agregaciones finales.

5. Capa de Monitoreo (Observabilidad GCP)

Tu diagrama utiliza la suite nativa de operaciones de Google Cloud.

- **GCP Logging Analytics:**
 - **Función:** Centralización de logs.
 - **Acción:** Recolecta los Job Logs de Dataproc y del DAG de Composer. Permite investigar por qué falló un proceso específico.
- **GCP Cloud Monitoring:**
 - **Función:** Métricas de rendimiento.
 - **Acción:** Visualiza la duración de los trabajos (Job Duration), uso de recursos y salud del pipeline.
- **Alerting Email:**
 - **Acción:** Si Monitoring detecta un fallo (ej. el DAG falló o el Stored Procedure dio error), envía automáticamente un correo al equipo de datos.

6. Visualización (Business Intelligence)

- **Looker Studio:**
 - **Función:** Interfaz de usuario.
 - **Acción:** Conecta directamente a **BigQuery Analytics**. Los usuarios consumen tableros dinámicos sin acceder a las capas crudas ni al código de orquestación.