

INFORME TÉCNICO

SOLUCIÓN DE ANALÍTICA DE VENTAS Y BI PARA CENCOSUD EN GCP

1. Arquitectura Cloud Definida

La arquitectura Cloud definida responde a la necesidad de modernizar la infraestructura de datos de Cencosud, migrando de procesos manuales y sistemas legados a un ecosistema de **Data Lakehouse** nativo en la nube. El diseño se centra en el procesamiento masivo de datos transaccionales (Big Data) bajo un enfoque *Serverless* (sin servidor), garantizando escalabilidad automática durante picos de venta (ej. Cyber Days), seguridad bancaria mediante encriptación y democratización del acceso a la información.

A continuación, se realiza una comparación técnica entre **Google Cloud Platform (GCP)**, **Amazon Web Services (AWS)** y **Microsoft Azure** para justificar la selección de GCP como la plataforma idónea para este proyecto de analítica avanzada en Retail.

Comparativa de Proveedores Cloud


Criterio	Google Cloud (GCP)	AWS	Microsoft Azure	Ganador
Data Warehouse	BigQuery: Serverless puro. No requiere gestión de clústeres. Separa almacenamiento de cómputo automáticamente. Rendimiento superior en petabytes.	Redshift: Requiere gestión de clústeres y provisionamiento (versión serverless existe pero es compleja de configurar).	Synapse Analytics: Potente pero con una curva de aprendizaje alta y configuración compleja de recursos dedicados.	GCP (Simplicidad y potencia)
Procesamiento Spark	Dataproc Serverless: Ejecución de jobs PySpark sin administrar clústeres Hadoop. Inicio rápido (segundos).	EMR Serverless: Potente pero con tiempos de arranque más lentos y configuración de políticas IAM compleja.	HDInsight / Synapse Spark: Requiere mayor gestión de infraestructura subyacente.	GCP (Eficiencia operativa)
Visualización & BI	Looker / Looker Studio: Integración nativa con BigQuery. Capa semántica robusta. Conexión directa sin mover datos.	QuickSight: Herramienta ágil pero carece de la profundidad de modelado semántico empresarial.	Power BI: Líder de mercado, pero requiere Gateways o configuración extra para optimizar la conexión con BigQuery.	GCP (Ecosistema nativo)

Costos Data Lake	Precios competitivos en almacenamiento (Cloud Storage) y consultas BigQuery bajo demanda (solo se paga por TB procesado).	S3 es económico, pero los costos de transferencia y procesamiento (GET/PUT) pueden escalar impredeciblemente.	Costos competitivos, pero el modelo de precios de Synapse puede ser confuso.	GCP (Transparencia)
-------------------------	---	---	--	-------------------------------

Justificación de la elección: La elección de **Google Cloud Platform** se fundamenta en su liderazgo en tecnologías de Big Data y Analítica. **BigQuery** elimina la sobrecarga operativa de administrar infraestructura, permitiendo al equipo de Cencosud enfocarse en la lógica de negocio (KPIs). Además, la arquitectura **Event-Driven** (impulsada por eventos) utilizando Pub/Sub y Cloud Functions permite una reactividad en tiempo real que las arquitecturas batch tradicionales de Azure o AWS (en sus configuraciones estándar) no ofrecen con la misma simplicidad.

2. Servicios Utilizados

Para garantizar el flujo de datos desde la ingesta hasta la visualización, se implementaron los siguientes servicios administrados:



a. Google Cloud Storage (GCS) - Fase: Ingesta (Data Lake)

Actúa como la "Zona de Aterrizaje" (Landing Zone). Es un almacenamiento de objetos altamente duradero y seguro.

- **Función:** Almacenar los archivos CSV crudos (raw) provenientes de los sistemas POS y E-commerce, así como los scripts de procesamiento.
- **Ventaja:** Costo extremadamente bajo, clases de almacenamiento (Standard/Coldline) y disparadores de eventos nativos.

b. Cloud Functions & Pub/Sub - Fase: Automatización (Event-Driven)

- **Cloud Functions (Gen 2):** Detecta la llegada de nuevos archivos al Data Lake.

- **Pub/Sub:** Sistema de mensajería asíncrona que desacopla la ingesta del procesamiento.
- **Ventaja:** Permite que el sistema reaccione automáticamente ("Trigger") sin intervención humana, garantizando que el ETL comience apenas llegan los datos.

c. Dataproc Serverless - Fase: Procesamiento ETL (Transformación)

Servicio gestionado de Apache Spark y Hadoop.

- **Función:** Ejecuta scripts de **PySpark** para la limpieza, deduplicación, casteo de tipos y transformación de datos a gran escala.
- **Ventaja:** No requiere administrar clústeres. Se paga solo por los segundos que dura el procesamiento del job.

d. Google BigQuery - Fase: Data Warehouse (Almacenamiento Analítico)

Es el corazón de la arquitectura.

- **Función:** Almacena las capas *Raw* (Tablas externas), *Curated* (Tablas nativas particionadas) y *Analytics* (Vistas Materializadas).
- **Ventaja:** Capacidad de procesar terabytes en segundos usando SQL estándar y optimización automática de consultas.

e. Cloud Composer (Airflow) - Fase: Orquestación

- **Función:** Gestiona el flujo de trabajo (DAG), controlando dependencias y reintentos en caso de fallos.
- **Ventaja:** Estándar de la industria (Apache Airflow) totalmente gestionado por Google.

f. Looker Studio - Fase: Visualización

- **Función:** Conexión directa a BigQuery para consultar datos y presentar los KPIs.
- **Ventaja:** Interfaz intuitiva y conexión nativa de alta velocidad con el almacén de datos.

3. Diseño del Data Lakehouse (Arquitectura por Capas)

Se utilizó una arquitectura "Medallion" para organizar los datos dentro de BigQuery y GCS, asegurando trazabilidad, calidad y gobierno del dato.

1. Capa Raw (Bronce)

- **Ubicación:** Google Cloud Storage (gs://bucket/raw/) y BigQuery External Tables.
- **Contenido:** Datos crudos tal cual llegan del origen (CSV). No se aplican cambios de formato ni limpieza profunda.
- **Justificación:** Permite re-procesar la historia completa si cambian las reglas de negocio y sirve como auditoría de la fuente original.

2. Capa Curated (Plata)

- **Ubicación:** Tablas Nativas de BigQuery (Formato interno Columnar/Capacitor).
- **Contenido:** Datos limpios, deduplicados, tipados y enriquecidos.
- **Procesos Aplicados:**
 - Conversión de cadenas a tipos DATE o FLOAT.
 - Manejo de nulos (ej. sk_promocion = -1 para ventas sin promoción).
 - Estandarización de textos (Mayúsculas, trim).
 - Particionamiento por fecha de transacción para optimizar costos de consulta.
- **Justificación:** Fuente confiable y "limpia" para científicos de datos y analistas técnicos.

3. Capa Analytics (Oro)

- **Ubicación:** Vistas Materializadas o Tablas Agregadas en BigQuery.
- **Contenido:** Datos agregados y modelos dimensionales (Esquema Estrella). Contiene el "Tablón Analítico" (resumen_ventas_analytics).
- **Justificación:** Optimizado para la velocidad de lectura en Looker. Pre-calcula KPIs complejos (SUM, AVG) para reducir la latencia del dashboard.

4. Modelo Dimensional Implementado

El modelo de datos se diseñó bajo un esquema de estrella para optimizar las consultas OLAP requeridas por los KPIs financieros y de clientes.



Tablas de Dimensiones

- dim_cliente_curated: Datos demográficos, tipo de cliente y ubicación.

- `dim_producto_curated`: Jerarquía de productos, categorías, marcas y unidades de medida.
- `dim_tienda_canal_curated`: Datos de tiendas físicas, canal (Online/Presencial) y ciudad.
- `dim_periodo_curated`: Calendario fiscal, mes, año, trimestre.
- `dim_promocion_precio_curated`: Detalles de campañas y descuentos.

Tabla de Hechos

- `fact_hecho_venta_curated`: Registro transaccional a nivel de ítem-ticket.
- **Métricas Base:** `monto_venta_bruta`, `monto_venta_neta`, `monto_margen`, `monto_descuento`, `num_secuencia` (unidades).

5. Procesos ETL Aplicados

Se implementó un flujo híbrido **ETL/ELT** aprovechando la potencia de Dataproc y BigQuery.

1. Proceso de Extracción (Extract):

- Los archivos CSV se suben a GCS simulando la extracción de los sistemas POS.
- **Justificación:** GCS ofrece durabilidad del 99% y actúa como buffer.

2. Proceso de Transformación (Transform):

- Se utiliza **PySpark** en Dataproc Serverless.
- Se leen los CSVs desde GCS.
- Se aplican reglas de negocio: `lower()`, `trim()`, `cast()`, y `fillna()` para integridad.
- **Justificación:** Spark permite procesamiento distribuido en memoria, ideal para volúmenes masivos que Excel no soporta.

3. Proceso de Carga (Load):

- Los DataFrames transformados se escriben directamente en BigQuery usando el conector `spark-bigquery-connector`.
- **Justificación:** Escritura paralela eficiente y disponibilidad inmediata para consulta SQL.

6. Scripts y Lógica de KPIs (SQL / Lógica de Negocio)

A continuación, se detalla la lógica SQL implementada en la capa Analytics para el cálculo automatizado de los KPIs definidos en el informe de negocio.

6.1. Indicadores Financieros y Operativos

KPI	Fórmula / Lógica SQL Implementada	Periodicidad	Fuente
Ticket Promedio	<code>SUM(monto_venta_neta) / COUNT(DISTINCT cod_ticket)</code>	Diario	Fact Venta


Margen Promedio	$\text{SUM(monto_margen) / COUNT(DISTINCT cod_ticket)}$	Diario	Fact Venta
% Descuento	$(\text{SUM(monto_descuento) / SUM(monto_venta_bruta)}) * 100$	Mensual	Fact Venta
% Tickets con Promo	$(\text{COUNT(DISTINCT CASE WHEN sk_promocion IS NOT NULL THEN cod_ticket END) / COUNT(DISTINCT cod_ticket)}) * 100$	Mensual	Fact Venta
Venta por Categoría	$\text{SUM(monto_venta_neta) GROUP BY categoria}$	Mensual	Fact + Dim Prod

6.2. Indicadores de Fidelización (CRM)

KPI	Fórmula / Lógica SQL Implementada	Periodicidad	Fuente
Frecuencia de Compra	$\text{COUNT(DISTINCT cod_ticket) / COUNT(DISTINCT sk_cliente)}$	Mensual	Fact + Dim Cliente
Monto Promedio Cliente	$\text{SUM(monto_venta_neta) / COUNT(DISTINCT sk_cliente)}$	Mensual	Fact + Dim Cliente
Participación Canal	$(\text{SUM(CASE WHEN canal='Online' THEN venta END) / SUM(venta total)}) * 100$	Mensual	Fact + Dim Tienda

7. Visualizaciones Finales Implementadas

Se implementó un Dashboard Ejecutivo en **Looker Studio** conectado a la tabla analítica resumen_ventas_analytics de BigQuery.




Dashboard General



DASHBOARD DE CLIENTES



desc_tipo_cliente






Tipo de Cliente		Cantidad
1.	MINORISTA	17.110
2.	ONLINE	4.725
3.	MAYORISTA	2.354

	desc_canal	cadena	desc_tipo...	Ticket Promedio
1.	PRESENCIAL	METRO	MINORISTA	S/ 78.84
2.	PRESENCIAL	WONG	MINORISTA	S/ 78.1
3.	ONLINE	METRO	MINORISTA	S/ 80.17
4.	PRESENCIAL	METRO	ONLINE	S/ 45.02
5.	ONLINE	WONG	MINORISTA	S/ 79.69
6.	PRESENCIAL	WONG	ONLINE	S/ 45.03
7.	PRESENCIAL	METRO	MAYORISTA	S/ 38.34
8.	ONLINE	METRO	ONLINE	S/ 45.5
9.	PRESENCIAL	WONG	MAYORISTA	S/ 38.9
10.	ONLINE	METRO	MAYORISTA	S/ 41.11
11.	ONLINE	WONG	ONLINE	S/ 44.54
12.	ONLINE	WONG	MAYORISTA	S/ 39.23

Dashboar de clientes



DASHBOARD COMERCIAL



	Cadena	Canal	Ticket Promedio
1.	METRO	PRESENC...	S/ 106.86
2.	WONG	PRESENC...	S/ 107.3
3.	METRO	ONLINE	S/ 106.83
4.	WONG	ONLINE	S/ 107.23

1 - 5 / 5 <

Dashboar comercial



DASHBOARD DE CANALES



desc_canal



Canal	Monto de margen
1. PRESENCIAL	578.827,04
2. ONLINE	226.483,1

Canal	Monto de venta neta
1. PRESENCIAL	2.573.389,26
2. ONLINE	1.008.759,81

Canal	Cadena	Ticket Promedio	
1.	PRESENCIAL	METRO	S/ 105,85
2.	PRESENCIAL	WONG	S/ 107,29
3.	ONLINE	METRO	S/ 108,81
4.	ONLINE	WONG	S/ 107,2


	cadena	desc_canal	%Descuento sobre Venta Bruta	
1.	WONG	PRESENCIAL	2.92 %	
2.	WONG	ONLINE	2.9 %	
3.	METRO	ONLINE	2.87 %	
4.	METRO	PRESENCIAL	2.84 %	

1 - 5 / 5



Dashboar de canales

DASHBOARD DE PROMOCIONES



Dashboard de promociones

7.1. Conexión con BigQuery

Se utilizó el conector nativo de Google.

- **Justificación Técnica:** Permite aprovechar la velocidad de la *Materialized View* creada en BigQuery (tiempo de respuesta < 1 seg), evitando la latencia de importar datos (modo Import) y garantizando datos en tiempo real.

7.2. Componentes del Dashboard

1. **Tarjetas de Resultados (Scorecards):** Visualización inmediata de "Ticket Promedio" (S/ 108.37) y "Margen Global". Incluyen comparativas con el periodo anterior.
2. **Gráficos de Tendencia:** Líneas temporales para analizar la estacionalidad de las ventas netas.
3. **Barras de Categoría:** Ranking de ventas donde se identificó a "Carnes y Embutidos" y "Mascotas" como líderes.
4. **Segmentadores (Filtros):** Controles dinámicos por Ciudad, Tienda (Wong/Metro) y Año, permitiendo a la gerencia realizar análisis *drill-down*.

8. Uso del Repositorio GitHub

El código fuente del proyecto se gestiona bajo control de versiones para asegurar la colaboración y el despliegue continuo.

- **Rama principal:** feature/grupo09-init
- **Estructura de Carpetas:**
 - DW: Contiene todos los scripts SQL necesarios para la gestión del almacén de datos en **BigQuery**

- Dashboard: Esta carpeta centraliza los recursos relacionados con la capa de visualización. Contiene los accesos directos y referencias a los tableros implementados en Looker Studio, facilitando el acceso rápido a los reportes de KPIs financieros y operativos.
- Docs: Almacena la documentación funcional y técnica del proyecto. Aquí se resguardan los entregables claves como el presente Informe Técnico y diagrama de arquitectura, asegurando que el conocimiento del proyecto esté centralizado y accesible.
- ETL: Aloja el código fuente responsable del movimiento y transformación de los datos. Incluye:
 - Scripts de Python para las Cloud Functions (Triggers) que detectan la llegada de archivos.
 - Scripts de PySpark utilizados por Dataproc Serverless para la limpieza y transformación masiva de datos.
- **Gestión de Cambios:** Las integraciones de nuevas funcionalidades o correcciones se realizan mediante *Pull Requests (PR)* con revisión de código obligatoria.